


UNIVERSIDAD AUTÓNOMA DE NUEVO LEÓN

FACULTAD DE CIENCIAS FÍSICO MATEMÁTICO



TÍTULO DE LA TESIS

POR

JUAN JESÚS TORRES SOLANO

COMO REQUISITO PARCIAL PARA OBTENER EL GRADO DE

MAESTRÍA EN CIENCIA DE DATOS

MARZO 2025

UNIVERSIDAD AUTÓNOMA DE NUEVO LEÓN
FACULTAD DE CIENCIAS FÍSICO MATEMÁTICO

Los miembros del Comité de Tesis recomendamos que la Tesis «Título de la tesis», realizada por el alumno Juan Jesús Torres Solano, con número de matrícula 2173262, sea aceptada para su defensa como requisito parcial para obtener el grado de Maestría en Ciencia de Datos.

El Comité de Tesis

M.C. José Anastacio Hernández Saldaña
Asesor

Nombre del revisor C
Revisor

Nombre del revisor D
Revisor

Vo. Bo.

Dra. Azucena Yoloxóchitl Ríos Mercado
Subdirector de Estudios de Posgrado

San Nicolás de los Garza, Nuevo León, marzo 2025

*Aquí puedes poner tu dedicatoria
si es que tienes una.*

ÍNDICE GENERAL

Agradecimientos	x
1. INTRODUCCIÓN	1
2. DELIMITACIÓN Y PLANTEAMIENTO DEL PROBLEMA	4
3. JUSTIFICACIÓN	5
4. FORMULACIÓN DE OBJETIVOS	7
4.1. Generales	7
4.2. Específicos	7
5. MARCO TEÓRICO	8
5.1. Geofísica y Geoelectrica	8
5.1.1. Definición de Geofísica	8
5.1.2. Resistividad de la Tierra	8
5.1.3. Sondeo Eléctrico Vertical	10
5.2. Adquisición de Datos Geofísicos	14
5.2.1. Intervalo de Muestreo en SEV	14
5.2.2. Proceso de Adquisición In Situ	16

ÍNDICE GENERAL	v
5.3. Machine Learning en la Geofísica	17
5.4. Random Forests	18
5.4.1. Bootstrap aggregating	19
5.4.2. Selección Aleatoria de Características	19
5.4.3. Predicción por Agregación	19
5.4.4. Varianza y Overfitting	20
5.4.5. Bias-Varianza Tradeoff	21
5.5. Support Vector Machines	21
5.5.1. Hiperplano Separador	22
5.5.2. Clasificador de Margen Máximo	22
5.5.3. Clasificador de Margen Suave (Soft Margin)	23
5.5.4. Método del Kernel	23
5.5.5. Regresión por Vectores de Soporte (SVR)	24
5.6. Gradient Boosting Regression	24
5.6.1. Naturaleza Secuencial	24
5.6.2. Minimización de la Función de Pérdida	25
5.6.3. Ajuste a los Residuales	25
5.6.4. Shrinkage (Tasa de Aprendizaje)	25
5.6.5. Regularización	26
5.7. Métricas de evaluación	28

ÍNDICE GENERAL	VI
5.7.1. Coeficiente de Determinación (R^2 Score)	28
5.7.2. Raíz del Error Cuadrático Medio (RMSE - Root Mean Squared Error)	29
5.7.3. Error Absoluto Medio (MAE - Mean Absolute Error)	29
5.7.4. Error Porcentual Absoluto Medio (MAPE - Mean Absolute Percentage Error)	30
5.7.5. Residuo Medio (Mean Residual - Bias)	30
5.7.6. Desviación Estándar de los Residuos (Std Dev of Residuals) .	31
6. METODOLOGÍA	32
6.1. Análisis de datos iniciales y simulación	32
6.1.1. Datos iniciales	34
6.2. Preparación de datos	40
6.3. Evaluación, optimización y entrenamiento	45
6.3.1. Análisis de generalización y rendimiento	46
6.4. Test y evaluación	52
7. RESULTADOS Y CONCLUSIONES	54
A. Apéndice I	56

ÍNDICE DE FIGURAS

5.1. Estructura atómica del oro	9
5.2. Configuración general de electrodos	11
5.3. Esquema de la contribución de la respuesta eléctrica	13
5.4. Esquema del arreglo Wenner	13
5.5. Esquema del arreglo Schlumberger	13
5.6. Esquema del arreglo Dipolo-dipolo	14
6.1. Histogramas de los espesores identificados en los modelos de interpretación geofísica	34
6.2. Histogramas de las resistividades identificadas en los modelos de inversión geofísica	35
6.3. Boxplot de la distribución global de espesores por sitio	36
6.4. Boxplot de la distribución global de resistividad por sitio	37
6.5. Análisis de componentes principales en datos base	38
6.6. Matriz de correlación de variables iniciales	39
6.7. Valores de entrenamiento correspondientes al registro 100	43
6.8. Valores de entrenamiento correspondientes al registro 556	43
6.9. Valores de entrenamiento correspondientes al registro 900	44

6.10. Valores de entrenamiento correspondientes al registro 1640	44
6.11. Comparación de métricas de evaluación para diferentes conjuntos de entrenamiento	47

ÍNDICE DE TABLAS

5.1. Ejemplo de un registro de adquisición de SEV.	17
6.1. Resultados del modelo de resistividad por sitio.	33
6.2. Rango de espesores (mínimo y máximo) registrados por sitio.	41
6.3. Configuración de hiperparámetros para cada modelo. Se remarca en negrita el valor con la mejor generalización mediante k -Fold Cross- Validation usando GridSearchCV.	46
6.4. Configuración de hiperparámetros para cada modelo, correspondiente a la mejor generalización mediante k -Fold Cross-Validation usando GridSearchCV.	49
7.1. Configuración de hiperparámetros para cada modelo. Se remarca en negrita el valor con la mejor generalización mediante k -Fold Cross- Validation usando GridSearchCV.	54

AGRADECIMIENTOS

Aquí puedes poner tus agradecimientos. (No olvides agradecer a tu comité de tesis, a tus profesores, a la facultad).

CAPÍTULO 1

INTRODUCCIÓN

La aplicación de ciencia de datos en geofísica presenta oportunidades para su ejecución, siendo mayormente desarrollada en sísmica petrolera, considerando y aprovechando la gran cantidad de datos que se generan en las campañas de exploración, así como los datos interpretados de las mismas, otorgando elementos cruciales para el entrenamiento de modelos que permitan el reconocimiento de patrones en los datos, así como su etiquetado y correlación con secuencias geológicas; representando una oportunidad vigente de aplicación en métodos geofísicos.

La geofísica se encarga de explorar el medio terrestre, empleando métodos que aprovechan las propiedades físicas del subsuelo como medio de respuesta ante la interacción activa o pasiva, ya sea mediante a la inducción de una campo eléctrico o mediciones de las variaciones magnéticas de la tierra respectivamente, entre otros métodos, permite modelar e interpretar la respuesta del medio de acuerdo al objetivo de estudio.

El método geofísico de prospección geoelectrica aprovecha las propiedad de resistividad para caracterizar las distintas unidades del medio geológico, a partir de su capacidad de resistividad eléctrica, siendo de interés para este trabajo el método de inducción eléctrica en su modalidad de Sondeo Eléctrico Vertical (SEV).

Los SEV se realizan siguiendo un arreglo geométrico de 4 electrodos previamente definido (ver figura 5.2), el cual puedo ejecutarse siguiendo la configuración Wenner, Dipolo-Dipolo o Schlumberger, entre otros, cada arreglo presenta un patrón distinto de dispersión del flujo eléctrico, cambiando su sensibilidad ante variaciones verticales u horizontales.

Durante la adquisición de datos en campo la apertura entre los electrodos cambia en razón al arreglo geoelectrónico empleado, de manera que obtenemos para cada cambio en apertura un valor de resistividad aparente, Rha o ρ_a en (Ωm), posterior al proceso de modelado e inversión, obtenemos una distribución de espesores con una resistividad asociada a cada uno de ellos.

Convencionalmente la prospección eléctrica se aplica, procesa e interpreta siguiendo una metodología claramente establecida, esto no la exime de ser viable la mejora de cada uno de sus aspectos.

Algunas etapas de este proceso han sido optimizadas, como la automatización de la lectura de datos, dicho esto, en el proceso de planeación de adquisición y validación de lecturas en campo pueden mejorar por medio de modelos de aprendizaje, los cuales requieren un amplio número de datos para su entrenamiento.

Para realizar un entrenamiento efectivo, se requiere de un gran número de datos, este problema se solventa mediante la simulación de variaciones de modelos de sondeos interpretados y verificados por exploración directa, siendo esto plausible al considerar la heterogeneidad del medio y manteniendo las variaciones dentro de los rangos de valor identificados en un mismo sitio.

Los datos de simulación (ρ, H) se conforman por rangos de espesores H y de resistividad ρ validados, a partir de los cuales se modela la resistividad aparente ρ_a considerando la apertura de electrodos original $AB/2$, estableciendo de esta manera los datos de entrenamiento $(\rho_a, AB/2, Z, \rho)$, los cuales corresponden a la resistividad aparente simulada ρ_a (variable de respuesta), apertura de electrodos $AB/2$, profundidad teórica de muestreo Z y la resistividad ρ del modelo para cada Z teórica.

El conjunto de datos cuenta con 8 sitios, integrados de 2 a 4 modelos interpretados, sumando un total de 25 SEV's, a partir de cada uno se generan 500 variaciones, en donde los espesores de las unidades definen el rango entre los modelos de un mismo sitio.

Los datos de entrenamiento se componen de 1640 filas correspondientes a cada variante de los sitios y 122 columnas integradas por ID, ID sitio, 30 registros de ρ_a , 30 registros de $AB/2$, 30 registros de Z y 30 registros de ρ ; con un total de 196,800 datos de entrenamiento.

Se realiza el entrenamiento empleando y comparando los modelos Support Vector Machines (SVM), Bayesian Compressive Sensing (BCS) y Random Forests (RF), los cuales se seleccionaron por su tolerancia a las características no paramétricas de los datos, el alto nivel de ruido que presente en la respuesta geoelectrica, si como una relación compleja entre las variables.

A partir de los resultados del entrenamiento se realiza pronósticos mientras se compara con datos reales de adquisición de un SEV ($AB/2$ y Rha), de igual manera, se realiza una comparación entre las puntuaciones (scorts) de las métricas de los modelos, se analizan los distintos grupos de entrenamiento, evaluando la mejor respuesta y el mejor ajuste en la predicción final.

la aplicación de Machine Learning (ML) representa un gran oportunidad de mejora en el proceso de planeación y adquisición de datos geofísicos, permitiendo establecer un conjunto de entrenamiento con pocos datos de entrada, con la posibilidad de validación en campo durante la adquisición e identificación de patrones, o bien, mediante reconocimiento geológico o expoliación directa.

CAPÍTULO 2

DELIMITACIÓN Y PLANTEAMIENTO DEL PROBLEMA

Durante un trabajo de prospección geoeléctrica, en adquisición de datos *in situ*, no es posible la interpretación directa del trabajo hasta una vez realizado el procesado y modelado de datos, por lo que no se tiene certeza de si la adquisición realizada en campo representara con claridad el objeto de prospección, es decir, si el muestreo realizado logra alcanzar el objetivo de exploración, y por consiguiente, representar con claridad las unidades geológicas de un sitio en particular.

El muestreo planificado, siempre incorpora algún grado de ambigüedad, relacionado con a la calidad de información empleada en su preparación, en el, se infiere la distribución y espesores de las unidades geoeléctrica, a partir de estudios previo, reconocimiento geológico de las unidades presentes en el área o incluso exploraciones directas en el sitio de estudio, sin embargo por este método, incluso considerando exploración directa en la planeación, es imposible inferir las propiedades geoeléctricas y distribución real del subsuelo.

Se evalúa como herramienta de pronóstico y mejora de muestreo *in situ* la implementación de técnicas de Machine Learning, a partir del entrenamiento de modelos de regresión, Random Forest (RF), Support Vector Machines (SVM) y Gradient Boosting Regression (GBR), con datos resultados interpretados y calibrados por sondeo directo, de manera que esto permita identificar oportunidades de mejora en adquisición y muestro.

CAPÍTULO 3 JUSTIFICACIÓN

Existen múltiples aplicaciones de ML en el procesamiento, modelado e interpretación geofísica (????), algunas de estas aplicaciones corresponden a implementaciones académicas, al igual que comerciales, mayormente desarrolladas en software de exploración sísmica de hidrocarburos (??).

La aplicación de ML durante la ejecución de muestreo de Sondeo Eléctrico Vertical (SEV), en particular durante el proceso de adquisición *in situ*, presenta la posibilidad de evaluar y ampliar el intervalo de muestreo original, mejorando la adquisición tradicional, realizando una predicción de muestreo en intervalos intermedios o finales durante la adquisición, identificando nuevos intervalos de apertura de electrodos no considerados previamente.

Durante el muestreo tradicional los intervalos se diseñan considerando el objetivo de exploración (idealmente), este análisis previo es un factor determinante, en esta etapa permitiendo establecer el intervalo de muestreo que permitirá identificar el objeto de exploración, o anomalía, su respuesta puede asociarse a unidades geológicas, acuíferos, fallas, zonas de fracturas, estructuras antropogénicas, infraestructura moderna, etc.

De manera general se busca mantener un intervalo de muestreo menor a la frecuencia de ocurrencia del objetivo de estudio, por lo que el éxito de la exploración dependerá en su totalidad de la planeación de la adquisición, lo que implica conocer previamente la conformación, distribución y espesor de cada unidad, aun contando con esta información, puede resultar complicado el procesamiento e interpretación de las anomalías, por la misma ambigüedad del ajuste de los modelos que satisfagan las curvas de inversión y la propia heterogeneidad del medio y de sus propiedades.

De manera que un modelo entrenado permita generar múltiples predicciones, en intervalos no explorados, e identificar regiones no cubiertas por el muestreo, permita contemplar la mejora de la adquisición con puntos adicionales *in situ* mejorando el intervalo de lectura e impactando en la calidad del muestreo, ajustando la respuesta geoelectrica.

Pese a existir aplicaciones de ML implementadas en geofísica, no se identifica alguna enfocada esta problemática en concreto (citar estudios de australia),

Para poder abordar la problemática se requiere de un modelo robusto ante el ruido, que permita trabajar con datos no paramétricos, sea favorable a la distribución de los datos, pueda establecer un modelo mediante entrenamiento supervisado, con capacidad de ejecutar regresiones a partir de entrenamientos previos y permita realizar pronósticos de valores de resistividad. Estas condiciones son cubiertas por tres modelos de ML Random Forests (RF), Support Vector Machines (SVM) y Gradient Boosting Regression (GBR), de los cuales mediante su evaluación, por medio de la puntuación de predicción, la facilidad de implementación y ejecución en pruebas con datos reales, permita identificar el que presenta el mejor rendimiento y ajuste para su implementación en la adquisición geofísica.

CAPÍTULO 4

FORMULACIÓN DE OBJETIVOS

4.1 Generales

- Realizar una evaluación de los modelos de Machine Learning que mejor se ajusten a las variables de entrenamiento, empleando datos simulados a partir de variaciones de modelos inversión validados, evaluando pronósticos a partir de datos de adquisición reales.

4.2 Específicos

- Identificar los modelos ML no paramétricos compatibles con las variables de entrenamiento, correspondientes a la etapa de adquisición en campo.
- Realizar comparación y evaluación de las métricas aplicadas a los modelos de entrenamiento.
- Establecer una comparativa entre la evaluación de pronósticos a partir de ensayos con datos de control.

CAPÍTULO 5 MARCO TEÓRICO

5.1 Geofísica y Geoeléctrica

5.1.1 Definición de Geofísica

En términos generales la geofísica es la aplicación de los principios físicos de la materia en el estudio del planeta Tierra, o cual quier otro cuerpo celeste, desde el campo magnético, pasando por los fenómenos atmosféricos al medio solido del subsuelo, hasta las profundidades del núcleo interno planetario, ya sea que se aproveche una fuente natural (propagación de ondas elásticas generadas por sismo), ó bien, de una fuente controlada (inducción de campo electromagnético) (???)


El nacimiento de la geofísica es relativamente reciente, la primera prospección geoeléctrica data de 1830 realizados por ? en Cornwall, Reino Unido, donde aplico técnicas de Self-Potential en exploración de mineralización de sulfuro en vetas, la medición del potencial natural resulto altamente efectiva para la prospección de este tipo de mineralizaciones ya que su anomalía se caracterizaba por presentar una respuesta muy marcada con respecto al medio circundante (??).

5.1.2 Resistividad de la Tierra

De manera general la materia presenta propiedades físicas únicas, definidas a partir de los elementos que la integran, y la configuración atómica que presentan, conformando moléculas orgánicas e inorgánicas, las cuales, pueden estar conformadas por una clase especifica de átomos (moléculas homonucleares) o por conjuntos de

diferentes tipos (compuestos), cuya conformación depende de factores físico-químicos (?).

La configuración molecular inorgánica presente en la materia, es decir su composición y configuración, define el tipo de estructura cristalina que formara a los minerales, así como sus propiedades físicas; esta configuración cristalina es la que encontramos en el medio geológico conformando los minerales que componen las rocas (ver figura 5.1) (??).



Estructura del Oro

FIGURA 5.1: Esquema de la estructura atómica de oro que conforma la cristalización octahedral, resistividad $\sim 2.35 \times 10^{-8} \Omega \cdot m$, modificado de ?.

Los métodos Geoelectricos se clasifican en dos grupos, métodos pasivos y de inducción, los primeros corresponden a aquellos en los que se mide el potencial eléctrico natural, usualmente medido en mili volts, en donde se requiere de electrodos no polarizables para tener medidas lo más claras posibles; mientras que los métodos de inducción emplean un arreglo de electrodos, o inductores de campo electromagnéticos, mediante los cuales se induce un campo eléctrico al subsuelo, calculando la diferencia de potencia eléctrica en el medio, o bien, el decaimiento de la polarización inducida (???)

Los métodos de inducción, Sondeo Eléctrico Verticales (VES, por sus siglas en inglés), Tomografía de Resistividad Eléctrica (ERT, por sus siglas en inglés), Polarización Inducida (IP, por sus siglas en inglés), presentan una gran ventaja

ya que no dependen del medio para poder realizar una lectura, además de poder realizarlos en cualquier momento, y puede diseñar arreglos de adquisición que nos permitan tener un muestreo tan amplio como sea conveniente, solo limitados por el alcance y potencia de los equipos empleados. Por otro lado su interpretación presenta un alta ambigüedad, solo acotado por la cantidad de referencias que puedan cruzarse para robustecer el modelo geológico y de inversión, y así poder llegar a una interpretación satisfactoria (??).

El método de prospección geoelectrica, en específico el SEV y la TRE, consiste en determinar la distribución de resistividades del subsuelo, de manera que se pueda establecer una correlación entre la resistividad y un modelo ajustado a la realidad geológica-estructural, geotécnica o geohidrológica del objeto de estudio.

5.1.3 Sondeo Eléctrico Vertical

Los SEV corresponden al método de mas rápida ejecución y económicamente mas accesible, por lo que es ampliamente empleado para solucionar problemas de ingeniería, minería, geotecnia, monitoreo e impacto ambiental y abastecimiento de Aguas potable; siendo de gran utilidad en la exploración de hidrogeologica ya que la respuesta resistiva de un medio saturado permite establecer diferencias concisas y discriminar entre agua dulce, salada, rocas fracturadas, arcillas , arenas, conglomerados, etc.

La resistividad es medida mediante la inyección de una corriente en el subsuelo al tiempo que se monitorea y captura la diferencia de potencial eléctrico en la superficie, esta lectura corresponde al valor de la contribución resistiva de todas las capas por donde fluye la corriente.

La inyección de corriente y medición del potencial se realiza a través de un arreglo de dos pares de electrodos, $A, B(C_1, C_2)$ y $M, N(P_1, P_2)$ respectivamente, siendo el electrodo $A(C_1)$ el polo positivo y $B(C_2)$ el polo negativo de inyección,

mientras que el electrodo $M(P_1)$ corresponde al polo positivo y $N(P_2)$ al polo negativo de los electrodos de potencial.




FIGURA 5.2: Configuración general de arreglo de electrodos, modificado de ?.

La resistividad del subsuelo se calcula a partir de la ley de Ohm, considerando el caso general en donde el medio es homogéneo y el arreglo de electrodos presenta una distribución convencional, donde se establece una relación directamente proporcional entre la resistencia R , medida en Ohm (Ω), y el cociente entre la diferencia de potencial ΔV y la corriente inducida I , para un valor puntual (?).

$$R = \frac{\Delta V}{I} \quad (5.1)$$

Sabiendo que se puede calcular R para una sección con longitud L y un área A , transversal del material, conociendo la resistividad (ρ) del material (??), podemos reescribir la ecuación como:

$$R = \rho \frac{L}{A} \rightarrow \rho = R \frac{A}{L} \rightarrow \rho = R \cdot k \quad (5.2)$$

Donde la resistividad (ρ) es una constante de proporcionalidad del medio y k es el factor geométrico de distribución del flujo de corriente en términos de la del arreglo de los electrodos de inducción y potencial (distancias entre los electrodos A-M-N-B) (??).

$$k = 2\pi \left(\frac{1}{AM} - \frac{1}{AN} - \frac{1}{BM} + \frac{1}{BN} \right) \quad (5.3)$$

Tenemos que la resistividad aparente (ρ_a) de una sección del subsuelo, corresponde a la contribución resistiva de las unidades geológicas en esa sección, en términos de las distancias entre electrodos, la diferencia de potencial y el flujo de corriente en el medio (??), esta dado por la siguiente ecuación:

$$\rho_A = \frac{\Delta U}{I} \cdot k \quad (5.4)$$

5.1.3.1 Arreglo de Electrodos y Factor Geométrico

Cada arreglo presenta ventajas, desventajas, rango de sensibilidad y espacio de ejecución, debido a estas características y se tiene que evaluar e identificar que arreglo cumple con las condiciones adecuadas para ser ejecutado, considerando el espacio disponible en el sitio de estudio, el nivel de ruido (motores, conexiones a tierra mal aterrizadas, antenas, postes metálicos, arboles), la profundidad de objeto de prospección y la resolución vertical alcanzable (ver figura 5.3).

Como se menciona, el valor de resistividad medido en campo se determina considerando la configuración geométrica de electrodos durante una medición, las distintas configuraciones de electrodos se encuentran ampliamente documentadas, cada una presenta un factor geométrico distinto (??), los principales arreglos geoelectricos para SEV's son:

Wenner

$$\rho_A = 2\pi \cdot R \cdot a \quad (5.5)$$

Schlumberger

$$\rho_A = \frac{\pi a^2}{b} \left[1 - \frac{b^2}{4a^2} \right] \cdot R, \quad a \geq 5b \quad (5.6)$$




FIGURA 5.3: Esquema de la contribución de la respuesta de resistividad eléctrica, modificado de ?.




FIGURA 5.4: Esquema del arreglo Wenner, modificado de ?.




FIGURA 5.5: Esquema del arreglo Schlumberger, modificado de ?.

Dipolo-dipolo

$$\rho_A = \pi n(n+1)(n+2)a \cdot R \quad (5.7)$$




FIGURA 5.6: Esquema del arreglo Dipolo-dipolo, modificado de ?.

5.2 Adquisición de Datos Geofísicos

Previo al trabajo de adquisición se realiza un análisis de entorno, en el cual se verifica la viabilidad del arreglo dadas las condiciones del sitio, considerando los siguientes aspectos, como el espacio disponible en el sitio de estudio, profundidad de exploración, nivel de ruido eléctrico, interferencias con la estabilidad del potencial natural del subsuelo, profundidad del objeto de exploración y dimensiones aproximadas del mismo.

5.2.1 Intervalo de Muestreo en SEV

El intervalo de muestreo empleado durante la adquisición de un SEV es un parámetro crítico que influye en la calidad y precisión de los datos geofísicos adquiridos, ya que esta estrechamente relacionado con la resolución vertical que deseamos de acuerdo al objeto de estudio. Durante la planeación es necesario considerar distintas condiciones, como son:

- Los espesores de cada unidad.
- La distribución de las distintas unidades.
- Profundidad de investigación
- Ruido en la señal.

Para establecer un intervalo de muestreo apropiado, se deben considerar el Teorema de Muestreo de Nyquist y El teorema de Shannon-Hartley (teorema de codificación de canal ruidoso), al igual que la geometría del arreglo geoelectrico empleado.

El Teorema de Muestreo de Nyquist, el cual, es un principio fundamental en el procesamiento de señales analógicas y digitales, establece las condiciones mínimas necesarias para la reconstrucción una señal analógica a partir de muestras discretas (?).

Nyquist nos garantiza las condiciones necesarias y suficientes para llevar a cabo una adquisición exitosa de muestreo de una señal, llámese distribución de resistividad en un medio heterogéneo y discontinuo (?), considerando siempre los espesores como inferidos a partir de muestreo directo.

$$f_s \geq 2 \cdot f_{max} \quad (5.8)$$

Donde la frecuencia de muestreo f_s es por lo menos dos veces mayor a la frecuencia máxima f_{max} conocida, cuando el teorema no se cumple se genera una distorsión en la señal, sumando las frecuencias altas incompletas a la señal natural de baja frecuencia, generando ruido, y problemas de interpretación, se conoce como aliasing (?).

Considerando el medio geológico como una región con presencia constante de ruido eléctrico de fuentes tanto naturales como humanas, es imprescindible considerar el teorema de Shannon-Hartley aplicando apilamiento de muestreo como método de reducción de la relación ruido señal, durante la adquisición de datos; esto quiere decir calcular el promedio de muestreos continuos en un intervalo definido de aperturas entre electrodos.

5.2.1.1 Factores que Determinan el Intervalo de Muestreo

En el contexto de la adquisición de datos mediante SEV, el intervalo de muestreo es equivalente al espaciado entre puntos donde se realizan mediciones de resistividad del subsuelo. Este intervalo de muestreo debe ser lo mas pequeño posible, de modo que permita obtener muestras de resistividad (?), esta relación se define

de la siguiente manera:

$$f_s = \frac{1}{\Delta x} \quad (5.9)$$

Donde el intervalo de muestreo Δx debe ser menor a la mitad de la longitud de onda (λ_{min} , espesor) asociado al objetivo de exploración.

$$\Delta x \leq \frac{\lambda_{min}}{2} \quad (5.10)$$

5.2.2 Proceso de Adquisición In Situ

La adquisición de datos se realiza mediante la lectura directa en campo, tomando una primera lectura del potencial natural por medio de los electrodos M y N, se continua con la lectura al inducir corriente continua empleando un resistivímetro mediante un segundo par de electrodos A (C_1) y B (C_2), mientras se realiza la lectura de potencia en los electrodos M (P_1) y N (P_2), la lectura se realiza en intervalos regulares en instantes de inyección de corriente (?).

Durante la toma de datos es importante considerar los modelos previos realizados durante el análisis preliminar, ya que el considerar las resistividades esperadas para el sitio analizado, permiten tener control en la dispersión de datos, identificando lecturas erróneas y corrigiendo con una nueva lectura o cambios de apertura (?).

De esta manera durante la adquisición se busca tener claros los intervalos de muestreo, la profundidad aparente de exploración, el numero de muestras por apertura que se realizaran y la resistividad aparente (ρ_A) calculada para cada entrada (ver Tabla 5.1).

TABLA 5.1: Ejemplo de un registro de adquisición de SEV.

Z	K	AB/2	MN/2	Pn 1	Pi 1	I 1	Pn 2	Pi 2	I 2	ρ_A 1	ρ_A 2	ρ_A
		(m)	(m)	(mV)	(mV)	(A)	(mV)	(mV)	(A)		($\Omega \cdot m$)	
1.2	12.566	2	0.5	12	1700	308	-7	1800	329	68.9	69.0	68.97
3	78.539	5	0.5	10	298	320	11	299	321	70.7	70.5	70.54
6	314.159	10	0.5	7	140	426	7	138	419	98.1	98.1	98.06
6	78.539	10	2	63	487	415	63	486	415	80.2	80.1	80.12
12	314.159	20	2	65	78	8	67	80	9	510.5	453.8	488.98
18	706.858	30	2	69	83	10	68	83	10	989.6	1060.3	1036.73

5.3 Machine Learning en la Geofísica

La aplicación de Machine Learning (M.L.) en geofísica a sido mayormente desarrollada en exploración sísmica, abarcando los procesos de adquisición, mejorando los tiempos de procesamiento, clasificación e interpretación, ya que es en este método donde se cuenta con la mayor cantidad de datos para entrenamiento por estudio (?); en menor medida se implementan técnicas de M.L. en la exploración y prospección geoelectrica, hay algunos ejemplos destacables como son ???, sin embargo no es un estándar en la metodología, pese a las ventajas que puede tener su aplicación, como es evaluado en este estudio.

El M.L. se integra de técnicas estadísticas avanzadas que utilizan algoritmos que permiten a la maquina reconocer patrones, aprender de ellos y generar pronósticos, a partir de datos estructurados, requiriendo un conjunto lo suficientes mente grande para poder realizar un entrenamiento robusto.

Podemos clasificar los algoritmos de M.L. por el tipo de entrenamiento que ejecutan, correspondiendo a aprendizaje supervisado, no supervisado y por refuerzo, de igual forma se distinguen por los parámetros del conjunto de datos de entrenamiento al que mejor se adaptan, es decir, pueden ser modelos paramétricos y no paramétricos (?).

Dada la naturaleza de los datos de SEV's, heterogéneos, discontinuos y no lineales (ver Tabla 5.1), es conveniente abordar su análisis desde un enfoque no paramétrico, teniendo esto en cuenta, los modelos para su entrenamiento requieren destacar en tareas de clasificación y regresión, considerando la reducción del sobre ajuste, interpretación de variables, resistencia al aliasing.

Los modelos no paramétricos destacan por su adaptabilidad a la estructura subyacente de los datos, realizando aprendizaje de relaciones complejas entre variables predictoras, así como datos ausentes de linealidad, característica presente en la mayoría de datos geofísicos y por tanto idóneos para este trabajo, sin embargo su implementación tiene un costo alto en volumen de datos requeridos para su entrenamiento, entre los modelos no paramétricos que mejor se adaptan a estas características, destacan los siguientes algoritmos de M.L.:

- Random Forests
- Support Vector Machines
- Gradient Boosting Regression

5.4 Random Forests

Random Forests es una técnica propuesta por ?, la cual emplea múltiples árboles de decisión independientes entre sí, donde cada árbol realiza una votación de clases, seleccionando la más popular de la entrada de cada árbol realizando una combinación de salida, permitiendo realizar una clasificación de características complejas o realizar regresiones de datos complejos multivariantes (??).

La herramienta de Random Forests, de acuerdo con ? emplea tres elementos clave en el proceso de entrenamiento, bagging, selección aleatoria de características y agregación por votación, resultando en la combinación de los resultados en una predicción o clasificación robusta y ajustada (?).

5.4.1 Bootstrap aggregating

Esta característica de Random Forest genera una colección de M árboles de decisión no correlacionados, cada uno de ellos se entrena utilizando muestras aleatorias del conjunto de datos originales, identificados como datos de entrenamiento D , este proceso se conoce como bootstrap aggregating (?).

De acuerdo con ?, Random Forests es un conjunto de clasificadores $H(x, \theta_k)$, x es un vector de entrada y θ_k corresponden a vectores aleatorios independientes generados a partir de los datos de entrenamiento D , con árboles k (donde $k = 1, 2, \dots, M$), esta aleatoriedad puede generar datos replicados en Θ_k , mientras que otros árboles pueden estar faltantes. La dimensión Θ_k es aproximadamente el 80 % del tamaño de D .

5.4.2 Selección Aleatoria de Características

Al construir cada árbol, en cada nodo, en lugar de considerar todas las características para encontrar la mejor división, se selecciona aleatoriamente un subconjunto de K características

En cada nodo de los subconjuntos de entrenamiento se selecciona una característica por votación de popularidad, dejando crecer cada árbol sin realizar poda hasta completar los criterios de finalización, es decir un número de instancias pre-establecido (?).

5.4.3 Predicción por Agregación

La clasificación para una entrada x se basa en las predicciones individuales de los árboles para cada clase $h_k(x)$, se realiza un conteo de cada clase, producto de la predicción de cada árbol, sumando las salidas $I(h_k(x) = c)$, y finalmente se selecciona la clase con mayor número de predicciones, obteniendo la predicción de

clasificación $H(x)$, donde x es una función indicadora que vale 1 si $h_k(x) = c$, y 0 en caso contrario (?).

$$H(x) = \operatorname{argmax}_c \sum_{k=1}^K I(h_k(x) = c) \quad (5.11)$$

El proceso de la regresión se obtiene a partir de la media aritmética de cada predicción individual, donde cada árbol produce un valor numérico $h_k(x)$ correspondiente a cada x , al corresponder con promedio de las predicciones se le otorga mas estabilidad cuando tenemos un numero elevado de arboles y un conjunto de datos grande, entendiéndolo como un modelo central que incorpora información de cada árbol (?).

$$H(x) = \frac{1}{K} \sum_{k=1}^K h_k(x) \quad (5.12)$$

5.4.4 Varianza y Overfitting

Algo notable en el algoritmo Random Forest es su capacidad para reducir la varianza sin que esto afecte significativamente el sesgo, lo que ayuda a evitar el overfitting (sobre ajuste), ya que el bagging, ejecutado durante el proceso de bootstrap, reduce la varianza al promediar las predicciones de múltiples modelos entrenados en diferentes árboles. La selección aleatoria de características descorrelaciona aún más los árboles, lo que contribuye a la reducción de la varianza (??).

La varianza de un Random Forest puede expresarse aproximadamente como:

$$\operatorname{Var}(JM_{RF}) = \rho(x)\sigma^2 + \frac{1 - \rho(x)}{M}\sigma^2 \quad (5.13)$$

Donde σ^2 es la varianza promedio de cada árbol y $\rho(x)$ es la correlación promedio entre las predicciones de cualquier par de árboles k . A medida que el número

de árboles M aumenta, el segundo termino tiende a cero, acercando la varianza a $\rho(x)\sigma^2$ (??).

5.4.5 Bias-Varianza Tradeoff

El objetivo en el aprendizaje automático es encontrar un modelo que minimice el error de prueba esperado ($E[E_{TEST}]$)(?), el cual puede descomponerse en sesgo al cuadrado ($Bias^2$), varianza (Var) y ruido ($Noise$):

$$E[E_{TEST}] = Bias^2 + Var + Noise$$

Con el método Random Forest se busca un equilibrio entre sesgo y varianza, considerando que los árboles individuales por lo general tienen un bajo sesgo y alta varianza, siendo equilibrado por el proceso bootstrap al reducir la varianza del ensamble, resultando en un mejor rendimiento general en datos no vistos (?).

5.5 Support Vector Machines

Este algoritmo de aprendizaje supervisado tiene como objetivo encontrar el hiperplano que mejor separa las clases en el espacio de características, maximizando la distancia entre este y los puntos más cercanos de cada clase, conocidos como vectores de soporte. En casos donde los datos no son linealmente separables, permite ciertas violaciones del margen mediante un parámetro de penalización que controla el equilibrio entre precisión y generalización, además, mediante el uso de funciones kernel, es posible proyectar los datos a espacios de mayor dimensión para lograr una separación lineal que no sería posible en el espacio original(??).

En problemas de regresión se emplea la variante Support Vector Regression (SVR). En este caso, el modelo busca una función que se mantenga dentro de un margen de tolerancia ϵ respecto a los valores reales, permitiendo cierto grado de error controlado por variables de holgura(?).

Tanto en clasificación como en regresión, SVM es una técnica robusta, especialmente útil en espacios de alta dimensión, aunque su desempeño depende de una adecuada elección de hiperparámetros y de kernel.

5.5.1 Hiperplano Separador

En la clasificación binaria más simple, cuando los datos son linealmente separables, el objetivo es encontrar un hiperplano que divida claramente las dos clases. En un espacio de p dimensiones, dicho hiperplano se define por la ecuación (?):

$$w^T x + b = 0$$

donde:

- w es un vector de pesos que determina la orientación del hiperplano,
- x es el vector de características de una instancia,
- b es un escalar que define la posición del hiperplano (sesgo).

Un hiperplano separador cumple que $w^T x + b > 0$ para una clase y $w^T x + b < 0$ para la otra.

5.5.2 Clasificador de Margen Máximo

El clasificador de margen máximo busca el hiperplano que maximiza la distancia (margen) entre las observaciones más cercanas de cada clase y el propio hiperplano (?). Estas observaciones se denominan *vectores de soporte*.

El problema de optimización se formula como:

$$\underset{w, b}{\text{minimizar}} \quad \frac{1}{2} \|w\|^2 \quad \text{sujeto a} \quad y_i(w^T x_i + b) \geq 1, \quad i = 1, \dots, n$$

donde $y_i \in \{-1, 1\}$ representa las clases. Esta formulación garantiza la separación de clases con el mayor margen posible.

5.5.3 Clasificador de Margen Suave (Soft Margin)

Cuando los datos no son perfectamente separables, se introducen variables de holgura $\xi_i \geq 0$ para permitir ciertas violaciones del margen:

$$\underset{w, b, \xi}{\text{minimizar}} \quad \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i \quad \text{sujeto a} \quad y_i(w^T x_i + b) \geq 1 - \xi_i$$

Aquí, $C > 0$ es un hiperparámetro que controla el compromiso entre la maximización del margen y la penalización por errores de clasificación (??).

5.5.4 Método del Kernel

Para datos no linealmente separables, SVM emplea el *truco del kernel*, que permite proyectar los datos a un espacio de mayor dimensión donde sí pueden ser separados linealmente, sin necesidad de calcular dicha proyección explícitamente (??).

Funciones kernel comunes:

- **Lineal:** $K(x_i, x_j) = x_i^T x_j$
- **Polinomial:** $K(x_i, x_j) = (x_i^T x_j + r)^d$
- **RBF (Gaussiano):** $K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2)$
- **Sigmoidal:** $K(x_i, x_j) = \tanh(\alpha x_i^T x_j + c)$

El problema de optimización dual con kernel se escribe como:

$$\begin{aligned} \underset{\alpha}{\text{maximizar}} \quad & \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j K(x_i, x_j) \\ \text{sujeto a} \quad & \sum_{i=1}^n \alpha_i y_i = 0, \quad 0 \leq \alpha_i \leq C \end{aligned}$$

La función de decisión para una nueva instancia x es:

$$f(x) = \text{sgn} \left(\sum_{i \in SV} \alpha_i y_i K(x, x_i) + b \right)$$

5.5.5 Regresión por Vectores de Soporte (SVR)

SVM también puede aplicarse a regresión mediante SVR, cuyo objetivo es encontrar una función $f(x)$ que tenga una desviación máxima de ϵ respecto a los valores verdaderos, penalizando sólo los errores mayores (??).

El problema se plantea como:

$$\begin{aligned} & \underset{w, b, \xi, \xi^*}{\text{minimizar}} \quad \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n (\xi_i + \xi_i^*) \\ & \text{sujeto a} \quad \begin{cases} y_i - (w^T x_i + b) \leq \epsilon + \xi_i \\ (w^T x_i + b) - y_i \leq \epsilon + \xi_i^* \\ \xi_i, \xi_i^* \geq 0 \end{cases} \end{aligned}$$

Donde ϵ define una región sin penalización y C regula el compromiso entre la planitud del modelo y la tolerancia a errores.

5.6 Gradient Boosting Regression

Gradient Boosting Regression es un método de aprendizaje ensamblado que construye modelos predictivos de manera secuencial. A diferencia de técnicas como Bagging y Random Forest, donde los árboles de decisión se construyen de forma independiente y se combinan al final, en Gradient Boosting cada nuevo árbol se entrena específicamente para corregir los errores cometidos por la suma de árboles anteriores. Esto permite una mejora progresiva en el desempeño del modelo a lo largo de múltiples iteraciones (??).

5.6.1 Naturaleza Secuencial

El modelo se construye de manera iterativa. Se inicia con una predicción base (por ejemplo, el promedio de las salidas) y, en cada iteración, se ajusta un nuevo

árbol de decisión sobre los errores cometidos por la suma de modelos anteriores. El resultado es un modelo compuesto por muchos árboles débiles, cuya combinación forma un modelo fuerte.

5.6.2 Minimización de la Función de Pérdida

En cada iteración, el algoritmo intenta minimizar una función de pérdida $L(y_i, \hat{f}(x_i))$, que cuantifica la discrepancia entre los valores reales y_i y las predicciones actuales $\hat{f}(x_i)$. La elección de la función de pérdida depende del tipo de problema (por ejemplo, el error cuadrático medio para regresión) (?).

5.6.3 Ajuste a los Residuales

El nuevo árbol se entrena sobre los *pseudo-residuales*, definidos como el gradiente negativo de la función de pérdida con respecto a las predicciones actuales. En el caso de regresión con error cuadrático, estos pseudo-residuales coinciden con los residuales clásicos:

$$r_i^{(b)} = y_i - \hat{f}^{(b-1)}(x_i)$$

Esto permite que cada nuevo árbol aprenda los patrones de error que el modelo anterior no pudo capturar.

5.6.4 Shrinkage (Tasa de Aprendizaje)

Para evitar que cada nuevo árbol domine demasiado el modelo, se introduce un parámetro de *shrinkage* o *tasa de aprendizaje*, denotado como $\lambda \in (0, 1)$ (??). Este factor escala la contribución de cada árbol:

$$\hat{f}^{(b)}(x) = \hat{f}^{(b-1)}(x) + \lambda \cdot f_b(x)$$

Valores pequeños de λ (como 0.01 o 0.001) ralentizan el aprendizaje, lo cual puede mejorar la generalización del modelo.

5.6.5 Regularización

Además del parámetro λ , se pueden emplear otras técnicas de regularización, como la profundidad máxima de los árboles (d), el número mínimo de muestras por hoja, o la fracción de datos usados en cada iteración (submuestreo) (?). Estas estrategias ayudan a reducir la varianza del modelo y mitigar el riesgo de sobreajuste.

5.6.5.1 Algoritmo de Gradient Boosting para Regresión

Antes de implementar este algoritmo es importante entender su dinámica iterativa y cómo se construyen las predicciones dentro del algoritmo, en donde optimiza una función de pérdida específica de manera directa mediante técnicas de gradiente, agregando modelos débiles (árboles de decisión) que corrigen los errores residuales del conjunto de modelos anteriores. El procedimiento se fundamenta en la minimización de una función de pérdida diferenciable, adaptando sucesivamente el modelo a los errores cometidos(???).

El siguiente esquema detalla las etapas de inicialización, el cálculo iterativo de los pseudo-residuales, el ajuste de árboles de regresión sobre dichos residuales y la actualización acumulativa del modelo predictivo, incluye la forma general de la salida final, que representa la suma ponderada de los árboles ajustados durante el proceso (???).

1. **Inicialización:** Se define una predicción inicial como:

$$\hat{f}^{(0)}(x) = \arg \min_c \sum_{i=1}^n L(y_i, c)$$

Por ejemplo, si L es el error cuadrático, entonces $\hat{f}^{(0)}(x) = \bar{y}$.

2. **Para cada iteración** $b = 1, 2, \dots, B$:

a) Cálculo de pseudo-residuales:

$$r_i^{(b)} = - \left[\frac{\partial L(y_i, \hat{f}^{(b-1)}(x_i))}{\partial \hat{f}(x_i)} \right]$$

(En el caso del error cuadrático: $r_i^{(b)} = y_i - \hat{f}^{(b-1)}(x_i)$)

b) Entrenar un árbol de regresión $f_b(x)$ sobre el conjunto $\{x_i, r_i^{(b)}\}$.

c) Actualizar el modelo:

$$\hat{f}^{(b)}(x) = \hat{f}^{(b-1)}(x) + \lambda f_b(x)$$

3. **Salida final:**

$$\hat{f}(x) = \hat{f}^{(B)}(x) = \hat{f}^{(0)}(x) + \lambda \sum_{b=1}^B f_b(x)$$

5.6.5.2 Parámetros de Ajuste Importantes

El rendimiento y la capacidad de generalización de un modelo de Gradient Boosting depende la configuración adecuada de ciertos hiperparámetros, permitiendo controlar tanto la complejidad del modelo como su comportamiento durante el entrenamiento, esto tiene un efecto directo en su precisión, robustez y riesgo de sobreajuste.

- **Número de árboles (B):** Controla la complejidad general del modelo. Más árboles pueden mejorar el ajuste, pero incrementan el riesgo de sobreajuste si no se regula adecuadamente.
- **Tasa de aprendizaje (λ):** Controla cuánto contribuye cada árbol al modelo final. Tiempos de entrenamiento más largos con λ pequeño suelen generar mejores modelos.
- **Profundidad del árbol (d):** Afecta la complejidad de cada árbol individual. Árboles muy profundos pueden capturar relaciones complejas pero también inducir sobreajuste.

5.6.5.3 Compensación Bias-Varianza

Gradient Boosting busca simultáneamente reducir el sesgo (bias) y la varianza del modelo. Al agregar secuencialmente modelos que corrigen errores anteriores, se reduce el sesgo. A su vez, mediante técnicas como el shrinkage, la poda de árboles y el submuestreo, se controla la varianza para evitar que el modelo se ajuste demasiado a los datos de entrenamiento (?).

En resumen, el algoritmo Gradient Boosting Regression construye un modelo fuerte combinando múltiples árboles débiles entrenados de forma secuencial. Cada nuevo árbol se enfoca en aprender los errores del modelo anterior, y su contribución se regula mediante una tasa de aprendizaje. Gracias a su capacidad para capturar patrones complejos y su flexibilidad, se ha convertido en una de las técnicas más potentes y ampliamente utilizadas en tareas de regresión y clasificación (????).

5.7 Métricas de evaluación

5.7.1 Coeficiente de Determinación (R^2 Score)

En el contexto de regresión, el R^2 no representa la precisión per se, sino la capacidad explicativa del modelo respecto a la varianza de los datos.

Definición: Es la proporción de la varianza total de la variable dependiente (resistividad aparente) que es predecible a partir de las variables independientes (aberturas de electrodos).

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Donde y_i es el valor real, $\hat{y}_i$ el predicho y $\bar{y}$ la media de los valores reales.

Interpretación en Data Science: Mide la bondad de ajuste. Un $R^2 = 0.98$

implica que el modelo captura el 98 % de la variabilidad del fenómeno físico, y solo el 2 % restante se debe a ruido aleatorio o factores no modelados.

5.7.2 Raíz del Error Cuadrático Medio (RMSE - Root Mean Squared Error)

Es la métrica estándar para medir la magnitud del error penalizando grandes desviaciones. Definición: Representa la desviación estándar de los residuos de predicción (errores de predicción). Es la norma L_2 escalada del vector de error.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Interpretación en Data Science: Debido al término cuadrático, el RMSE es altamente sensible a valores atípicos (outliers). Si el RMSE es mucho mayor que el MAE, indica que el modelo está cometiendo errores muy grandes en puntos específicos (probablemente en cambios litológicos abruptos), aunque ajuste bien el resto.

5.7.3 Error Absoluto Medio (MAE - Mean Absolute Error)

Una métrica de error lineal que ofrece una visión más robusta y menos sesgada por extremos.

Definición: Es el promedio de las diferencias absolutas entre el valor objetivo y el predicho. Matemáticamente corresponde a la norma L_1 escalada.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Interpretación en Data Science: Representa la "magnitud típica" del error. A diferencia del RMSE, trata a todos los errores por igual. Si tu MAE es $11 \, \Omega \cdot m$,

significa que, en promedio, tu predicción se desvía 11 unidades del valor real. Es una medida de robustez.

5.7.4 Error Porcentual Absoluto Medio (MAPE - Mean Absolute Percentage Error)

Crítico para problemas con rangos dinámicos amplios (como la resistividad, que varía de 10^1 a 10^4). Definición: Mide el error promedio como un porcentaje del valor real, proporcionando una evaluación invariante a la escala.

$$MAPE = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

Interpretación en Data Science: Permite comparar el desempeño en diferentes magnitudes. Un error de $10 \Omega \cdot m$ es insignificante si la resistividad real es $2000 \Omega \cdot m$ (0.5 %), pero catastrófico si es $20 \Omega \cdot m$ (50 %). El MAPE normaliza este efecto, indicando la fiabilidad relativa del modelo.

5.7.5 Residuo Medio (Mean Residual - Bias)

Esta métrica evalúa el sesgo sistemático del modelo. Definición: Es el promedio aritmético de los residuos (errores con signo).

$$Bias = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)$$

Interpretación en Data Science: Si $Bias \approx 0$: El modelo es insesgado; los errores positivos y negativos se cancelan (el ruido es aleatorio). Si $Bias > 0$: El modelo tiende a subestimar sistemáticamente los valores (si definimos residuo como $Real - Predicho$). Si $Bias < 0$: El modelo tiende a sobreestimar.

5.7.6 Desviación Estándar de los Residuos (Std Dev of Residuals)

Mide la consistencia o estabilidad del error del modelo. Definición: Cuantifica la dispersión de los errores de predicción alrededor del Residuo Medio.

$$\sigma_{res} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (e_i - \bar{e})^2}$$

Donde $e_i = y_i - \hat{y}_i$ es el residuo.

Interpretación en Data Science: Indica la precisión (en contraposición a la exactitud). Un modelo puede tener un sesgo bajo (Residuo Medio ≈ 0) pero una desviación estándar alta, lo que significa que es inestable y sus predicciones oscilan mucho (ruidosas”). Buscamos modelos con σ_{res} baja.

CAPÍTULO 6 METODOLOGÍA

El objetivo central de la metodología consiste en evaluar la eficacia de la generación de pronósticos de resistividad aparente a partir del entrenamiento supervisado de los modelos Random Forest, Gradient Boosting Regression y Vector Supporter Machine.

En ciencia de datos la cadena de procesos de análisis, se estructura y diseña rigurosamente para garantizar la calidad de los datos de entrada, la preparación y diseño de los datos de entrenamiento, la optimización de los modelos y la evaluación de los resultados, así como la comparación de cada modelo empleado.

El proceso metodológico se dividió en 5 etapas:

1. Análisis de datos iniciales y simulación
2. Limpieza y preparación de datos
3. Modelado y entrenamiento
4. Validación, optimización y comparación de modelos
5. Test y evaluación

6.1 Análisis de datos iniciales y simulación

Durante las etapas de adquisición *in situ*, se cuenta con información limitada generada en gabinete y los datos obtenidos durante la adquisición geofísica, estos últimos correspondiendo a profundidades aparentes de exploración, aperturas de

electrodos de corriente y potencial, así como a los resultados de resistividad aparente resultantes de cada lectura.

Ya que se cuenta con un numero limitado de variables, ρ_A , $AB/2$, Z y el modelo de unidades geológicas esperado, así como su valor de resistividad inferido, estos datos conforman los elementos básicos necesarios durante la exploración y por consiguiente se integran como base para el entrenamiento de los modelos.

Antes de poder ser empleadas las variables identificadas, es necesario establecer la fuentes de los datos, definir el formato adecuado y cubrir la dimensión y estructura necesaria en los datos para lograr un entrenamiento efectivo.

TABLA 6.1: Resultados del modelo de resistividad por sitio.

Modelo	Sitio	Espesor 1	Espesor 2	Espesor 3	Resistividad 1	Resistividad 2	Resistividad 3	Resistividad 4
S1-LN-EBSA	1	6.1	60.7	131.3	150.0	60.0	804.5	965.4
S2-LN-EBSA	1	6.4	78.4	113.5	196.01	60.0	4765.06	5718.0
S3-LN-EBSA	1	6.0	70.0	122.0	437.2	90.0	100.0	120.0
S1-AMEBSA	2	2.4	8.5	45.5	56.6	350.0	11 000.0	13 200.0
S2-AMEBSA	2	1.3	4.5	66.0	56.0	350.0	1500.0	1800.0
S3-AMEBSA	2	3.0	23.0	32.0	95.0	1500.0	4800.0	5760.0
S4-AMEBSA	2	3.0	9.0	63.0	4.0	45.0	3400.0	4080.0
S5-AMEBSA	2	3.5	9.0	41.0	48.0	460.0	2300.0	2760.0
S1-BMEBSA	3	3.0	7.0	20.0	125	3350.0	4020.0	
S2-BMEBSA	3	4.0	6.0	20.0	2.2	1500.0	1800.0	
S1-MFA-VER	4	2.9	19.9	37.2	86.7	13.4	195.4	234.4
S2-MFA-VER	4	1.7	15.7	42.6	21.8	1.9	80.0	96.0
S3-MFA-VER	4	1.7	5.6	52.7	26.1	77.8	32.5	39.0
S1-OA-VER	5	1.6	25.0	33.4	2.1	6.9	77.0	92.4
S2-OA-VER	5	0.7	6.4	43.6	38.0	1.0	70.0	84.0
S3-OA-VER	5	2.0	7.9	59.0	1.0	15.7	70.0	84.0
S1-LP-L-NL	6	2.36	15.8	53.8	111.6	1676.5	1271.4	1525.6
S2-LP-L-NL	6	4.0	20.7	47.3	398.77	690.16	1013.7	1216.4
S1-EGH-OLV	7	3.0	14.0	80.0	56.0	264.0	85.0	129.0
S2-EGH-OLV	7	10.0	26.0	204.0	17.0	48.0	360.0	432.0
S3-EGH-OLV	7	40.0	20.0	138.0	750.0	100.0	85.0	102.0
S1-ZR-P-EBSA	8	3.5	12.0	44.5	3.0	20.0	2000.0	2400.0
S2-ZR-P-EBSA	8	4.0	6.0	56.0	350.0	1300.0	2600.0	3120.0
S3-ZR-P-EBSA	8	8.0	37.0	20.0	250.0	2600.0	1800.0	2160.0
S4-ZR-P-EBSA	8	5.6	13.0	20.0	1300.0	3200.0	1800.0	5000.0

6.1.1 Datos iniciales

Se cuenta con un total de 8 sitios de exploración, los cuales están integrados por al menos con 2 Sondeos Eléctricos Verticales (SEV), en diferentes ambientes geológicos, reuniendo un total de 26 SEV's, correspondientes a sitios de exploración minera, geohidrológica y geotécnica, los cuales se modelaron, interpretaron y validaron mediante exploración por perforación o excavación (ver tabla 6.1).

Al analizar los histogramas correspondientes a los espesores, se identifica en los tres gráficos (ver figura 6.1) una marcada ocurrencia de unidades con espesores pequeños en cada conjunto; en el grafico Espesor_1 se asociado a la mayor ocurrencia de unidades poco desarrolladas con estratos geológicos sedimentarios superficiales, mientras que a mayor profundidad, Espesor_2 y Espesor_3, la ocurrencia de unidades geológicas con mayor desarrollo es mas recurrente, sin embargo esto no puede considerarse una norma al considerar la complejidad geológica de cada sitio particular.




FIGURA 6.1: Histogramas de los espesores en los modelos interpretados.

Mientras que los histogramas de resistividad presentan una ocurrencia mayor de valores bajos con colas largas y pesadas, es decir, se observan pocos espesores con un alto valor de resistividad y muchos con bajo valor (ver figura 6.2), este comportamiento esta directamente ligado directamente a la las unidades interpretadas que fueron muestreadas, y corresponde a una propiedad misma del medio explorado.




FIGURA 6.2: Histogramas de las resistividades en los modelos interpretados.

En la figura 6.3 se observa la distribución general entre los distintos sitio; en el primer grafico correspondiente al grupo 'Espesor_1' se identifica en el sitio 7 una alta dispersión así como una marcada asimetría en los datos dada la posición del Rango Intercuartílico mientras que en el resto se observa una marcada concentración en una posición baja; en el segundo grupo, 'Espesor_2', se identifica un ligero incremento en la dispersión general de los datos, manteniendo la simetría observada anteriormente; en el ultimo grupo de 'Espesor_3' una variación mayor en la posición de los cuartiles, manteniendo simetría con una mayor dispersión en el rango de amplitud de espesor.

los comportamientos observados en la figura 6.3 son los esperados para conjuntos de modelos interpretados en condiciones geológicas similares, mas no idénticas, mostrando un relaciona intrínseca de la heterogeneidad de los espesores identificados con la ambigüedad en la interpretación de los modelos de inversión.




FIGURA 6.3: Boxplot de la distribución global de espesores por sitio.

En la figura 6.4 se identifica una marcada similitud de dispersión, posición y simetría entre los gráficos de distribución de resistividad 3 y 4, dicha similitud cualitativa se asocia a la aproximación de valores resistivos en los límites del modelo de inversión, individualmente en los gráficos de distribución de resistividad 1, 2 y 3 se observa un aumento progresivo de la dispersión entre los gráficos, se observa que los sondeos 4, 5 y 6 presentan una posición estable en los tres gráficos, esta falta de dispersión se asocia a la baja profundidad de los sondeos y la presencia de un ambiente geológico muy similar en todo el rango de exploración.




FIGURA 6.4: Boxplot de la distribución global de resistividad por sitio.

Al realizar el análisis de componentes principales (PCA) identificamos que los primeros 4 componentes (Espesor 1, Espesor 2, Espesor 3 y Resistividad 1) describen casi el 92 % de la variabilidad de los datos, muy cerca del umbral del 95 %, siendo prácticamente no representativa la componente 7 (Resistividad 4).

1. PC1: 39.41 % (Espesor 1)
2. PC2: 28.88 % (Espesor 2)
3. PC3: 13.72 % (Espesor 3)
4. PC4: 9.74 % (Resistividad 1)
5. PC5: 4.58 % (Resistividad 2)
6. PC6: 3.61 % (Resistividad 3)
7. PC7: 0.06 % (Resistividad 4)




FIGURA 6.5: Análisis de componentes principales obteniendo la siguiente varianza por componente: 0.3941 0.2888 0.1372 0.0974 0.0458 0.0361 0.0006.

Al analizar los resultados cualitativos y cuantitativos resultantes de las evaluaciones estadísticas, se observa que las variables correspondientes a los 8 sitios corresponden a datos no relacionados y lo suficientemente independientes, este comportamiento se confirma al observar la matriz de correlación entre variables (ver figura 6.6), observando un valor de correlación general menor a 0.52, a excepción del valor obtenido entre la variable Resistividad_3 y Resistividad_4.




FIGURA 6.6: Matriz de correlación de variables iniciales, correspondientes a los conjuntos de datos modelos interpretados.

6.2 Preparación de datos

Debido al bajo volumen de datos iniciales generados en una campaña de exploración y su alto costo relativo, aunque significativo localmente para la interpretación de cada sitio, es insuficiente para establecer una base de entrenamiento robusta, por lo que es imprescindible contar con la cantidad de datos suficiente para el entrenamiento.

Para lograr el volumen de datos necesarios se implementa la generación de SEV's sintéticos, en esta tarea se emplea la librería PyGIMLI, publicada por ?, la cual permite realizar una simulación de sondeo a partir de unidades de espesor con un valor de resistividad establecido y la relación geométrica de apertura de los electrodos de corriente.

Al contar con datos de espesores y resistividad producto de una interpretación geoelectrica, cuyos valores (ver tabla 6.1) fueron validadas directamente para cada sondeo, se cuenta con la base necesaria para generar modelos sintéticos de respuesta geoelectrica; empleando los valores de apertura de electrodos ($AB/2$) de los sondeos originales.

En este punto es importante considerar cuatro aspectos, la heterogeneidad del subsuelo, las condiciones geotécnicas particulares del medio, el principio de equivalencia y la densidad de datos requeridos por los modelos para su entrenamiento; los dos primeros corresponden a factores cruciales que determinan el comportamiento eléctrico del medio y su respuesta; los últimos dos atañen a la complejidad de interpretación, relacionada con la cantidad de modelos requeridos para el entrenamiento y el infinito número de modelos de inversión de ajuste de la señal resultante.

Como estrategia se optó por una postura centrada en la aleatoriedad de las propiedades evaluadas y validadas, empleando los rangos máximos y mínimos de espesor y resistividad de cada sitio, teniendo en cuenta que los resultados obtenidos corresponden a condiciones geológicas similares pero con distinta respuesta

geoelectricas, cubriendo el aspecto de heterogeneidad del subsuelo y el principio de equivalencia, con rangos aleatorios de resistividad y espesor respectivamente (ver tabla 6.2).

TABLA 6.2: Rango de espesores (mínimo y máximo) registrados por sitio.

Sitio	variable	Mínimo	Máximo
1	Espesor 1	6.00	6.40
	Espesor 2	60.70	78.47
	Espesor 3	113.53	131.30
2	Espesor 1	1.30	3.50
	Espesor 2	4.50	23.00
	Espesor 3	32.00	66.00
3	Espesor 1	3.00	4.00
	Espesor 2	6.00	7.00
	Espesor 3	20.00	20.00
4	Espesor 1	1.70	2.90
	Espesor 2	5.60	19.90
	Espesor 3	37.20	52.70
5	Espesor 1	0.70	2.00
	Espesor 2	6.40	25.00
	Espesor 3	33.40	59.00
6	Espesor 1	2.36	4.00
	Espesor 2	15.80	20.70
	Espesor 3	47.30	53.80
7	Espesor 1	3.00	40.00
	Espesor 2	14.00	26.00
	Espesor 3	80.00	204.00
8	Espesor 1	3.50	8.00
	Espesor 2	6.00	37.00
	Espesor 3	20.00	56.00

Al considerar un estado *aleatorio* entre los rangos de valores de las variables,

evitamos el ajuste a una distribución sesgada, pasando a una distribución uniforme, evadiendo así el overfitting inicial, lo cual permite entrenar los modelos con todas las variaciones aleatorias posibles.

Inicialmente se establecen dos parámetros importantes, que definirán el volumen de datos de entrenamiento; el primero corresponde al número de aperturas de $AB/2$, con un tope máximo de 30 muestras, estableciendo la matriz de variables; en el segundo parámetro corresponde al número de variantes aleatorias entre los rangos para cada sitio - variable, establecida en 500 variaciones.

A partir de las variantes establecidas, espesor, rangos de aperturas y la resistividad, se ejecuta la simulación de la respuesta geoelectrica obteniendo los valores de ρ_A para cada $AB/2$, empleando el arreglo geométrico del método Schlumberger.

finalmente se integran a cada variante los últimos dos parámetros para el entrenamiento; la profundidad de exploración aparente, calculada a partir de la distancia entre electrodos $AB/2$, para cada $Z_i = (AB/2_i * 2) * 0.299$ (?); y el valor inicial de resistividad (ρ) modelada esperado en cada intervalo Z_i .

Adicionalmente se estableció un filtrado tomando como criterio el valor máximo Z_i , limitando las variaciones de espesores en función de Z_i , filtrando los registros que satisfagan el siguiente criterio:

$$\sum_{i=1}^n \text{Espesor}_i < \text{máx}(Z_i)$$

De esta manera obtenemos un total de 120 entradas, $AB/2_1, \dots, AB/2_{30}$, $Rhoa_1, \dots, Rhoa_{30}$, $Z_1, \dots, Z_{30}$ y $R_1, \dots, R_{30}$, para un total de 1640 sitios simulados.




FIGURA 6.7: Valores de entrenamiento correspondientes al registro 100, en donde se observan los valores de entrenamiento Rhoa (ρ_A) vs $AB/2$ y R (ρ) vs Z .




FIGURA 6.8: Valores de entrenamiento correspondientes al registro 556, en donde se observan los valores de entrenamiento Rhoa (ρ_A) vs $AB/2$ y R (ρ) vs Z .




FIGURA 6.9: Valores de entrenamiento correspondientes al registro 900, en donde se observan los valores de entrenamiento Rhoa (ρ_A) vs $AB/2$ y R (ρ) vs Z .




FIGURA 6.10: Valores de entrenamiento correspondientes al registro 1640, en donde se observan los valores de entrenamiento Rhoa (ρ_A) vs $AB/2$ y R (ρ) vs Z .

6.3 Evaluación, optimización y entrenamiento

Parte del proceso de implementación de los modelos Machine Learning (RF, VSM, GBR), requiere de la evaluación mediante *Cross-Validation* (GridSearchCV), la cual realiza 3 procesos iterativos, identifican el mejor ajuste de hiperparámetros que prioricen el desempeño, la reducción del sesgo y la maximización de las métricas de entrenamiento, este proceso divide el conjunto de datos en k -pliegues (Particiones), en donde la fracción mayor corresponde al conjunto de entrenamiento y la mínima al de evaluación.

En el proceso de evaluación del algoritmo GridSearchCV consideran un conjunto de entrenamiento de $k = 3$ y $k = 5$ pliegues. Esto permite analizar el equilibrio entre sesgo y varianza en la estimación del error predictivo de los datos de resistividad eléctrica (?).

En la practica, emplear configuración de $k = 3$, los algoritmos se entrenan utilizando el 66.6 % de los datos, lo que minimiza el costo computacional pero introduce un sesgo pesimista en la evaluación del rendimiento. Por otro lado, al emplear $k = 5$, el modelo se entrena con el 80 % de la información disponible, garantizando una estimación más robusta de su capacidad de generalización frente a perfiles geofísicos no vistos.

El algoritmo GridSearchCV, realiza una evaluación del entrenamiento en cada conjunto de particiones establecidas, sobre los cuales evalúa el conjunto de hiperparametros definidos (6.3) para los Modelo RF, SVM y GBR, cuantificando sus desempeños y realizando el entrenamiento con aquellas valores que maximicen las métricas de desempeño (ver figura

El conjunto de hiperparametros corresponden a campos específicos para cada modelo, en la tabla 6.3 se presentan el rango de valores evaluados en cada uno de los modelos ML.

TABLA 6.3: Configuración de hiperparámetros para cada modelo. Se remarca en negrita el valor con la mejor generalización mediante k -Fold Cross-Validation usando GridSearchCV.

Algoritmo	Hiperparámetro	Valores Evaluados
Random Forest	n_estimators	50, 100, 200, 500
	max_depth	10, 15, 20, 30, None
	min_samples_split	2, 5, 7, 10
Support Vector Machine	C	1, 10, 100, 150
	epsilon (ϵ)	0.1, 0.2, 0.5, 0.9
	kernel	Radial Basis Function
		Linear Function
Gradient Boosting Regressor	n_estimators	100, 200, 300, 500
	learning_rate	0.01, 0.1, 0.99
	max_depth	3, 5, 10

6.3.1 Análisis de generalización y rendimiento

Para evaluar la robustez y capacidad de generalización de los modelos, y frente a la recurrente distribución discontinua de los datos geofísicos, se analizó su rendimiento global bajo diferentes particiones de validación cruzada y la varianza del error predictivo a lo largo de las 30 columnas de pronóstico.

En la figura 6.11 se presentan los resultados del análisis comparando las particiones $k = 3$ y $k = 5$, con los resultados de las métricas, correspondientes al Coeficiente de Determinación (R^2 Score), Raíz del Error Cuadrático Medio (RMSE), Error Absoluto Medio (MAE), Error Porcentual Absoluto Medio (MAPE), Residuo Medio (Mean Residual) y Desviación Estándar de los Residuos (Std Dev of Residuals).

En los resultados (ver figura 6.11) se demuestran la superioridad de los méto-




FIGURA 6.11: Comparación de métricas de evaluación para diferentes conjuntos de entrenamiento, la columna izquierda integra los resultados para $k\text{-Fold}=3$, a la derecha muestra los de $k\text{-Fold}=5$.

dos basados en ensambles de árboles de decisión, específicamente *Random Forest* (RF) y *Gradient Boosting Regressor* (GBR), en los cuales la convergencia de las métricas entre ambos escenarios confirma que su modelo es estable y resistente a la variabilidad de las distribuciones espaciales del conjunto de datos, manteniendo coeficientes de determinación (R^2) superiores a 0.98 y valores de RMSE y MAE notablemente bajos.

En contraste, el modelo *Support Vector Machine* (SVM) presenta una penalización importante tanto en error absoluto como en varianza, evidenciando una menor flexibilidad para modelar las no-linealidades inherentes de los datos en este espacio de características (?).

Esta baja sensibilidad a la partición de los datos en RF y GBR es evidencia de que logran capturar la complejidad global del fenómeno geoelectrico sin incurrir en un sobreajuste significativo (*overfitting*), comportándose estables y resistentes a la variabilidad de las distribuciones espaciales del conjunto de datos dada la convergencia de las métricas entre ambos escenarios vista en los modelos RF y GBR. Tal como demuestra ? las particiones del orden de $k = 5$ a $k = 10$ son óptimas para estabilizar la varianza del modelo sin comprometer los tiempos de procesamiento, empleando convencionalmente la partición $k = 5$ la que presenta el mejor equilibrio entre conjuntos de entrenamiento y evaluación.

A partir del resultado de la evaluación del algoritmo GridSearchCV (Cross-Validation) empleando un valor de partición $k - pliques = 5$, se obtuvieron los hiperparámetros para cada modelo cuya generalización

Una vez establecidos los hiperparametros idóneos se realiza un análisis global del desempeño de los modelos de Machine Learning evaluando la varianza del error predictivo aplicado a los 30 niveles de capas de regresión o columnas de pronostico.

Por otro lado, el análisis de la varianza del error predictivo (evaluación por índice de columna de pronostico) expone la eficiencia del pronostico de los modelos. Al observar las métricas iterativas de MSE, Desviación Estándar y Curtosis, se hace

TABLA 6.4: Configuración de hiperparámetros para cada modelo, correspondiente a la mejor generalización mediante k -Fold Cross-Validation usando GridSearchCV.

Algoritmo	Hiperparámetro	Valores Evaluados
Random Forest	n_estimators	200
	max_depth	20
	min_samples_split	2
Support Vector Machine	C	150
	epsilon (ϵ)	0.1
	kernel	Radial Basis Function
Gradient Boosting Regressor	n_estimators	500
	learning_rate	0.1
	max_depth	3

evidente que el error predictivo del SVM se degrada sustancialmente (alcanzando valores de MSE superiores a 10,000 en las columnas centrales). Esto se debe a que SVM, al ser un algoritmo de optimización de márgenes espaciales, tiende a perder precisión frente a las transiciones abruptas y capas fuertemente contrastantes típicas de los perfiles de resistividad, a menos que el hiperparámetro de su núcleo (*kernel*) esté calibrado para cada estrato local de forma independiente (?).

Contrariamente, tanto RF como GBR mantienen una traza de error estable a lo largo de todas las columnas de pronóstico. La capacidad de los algoritmos basados en árboles para realizar particiones ortogonales y aislar subespacios locales les da una ventaja en el procesamiento con datos espaciales heterogéneos y variaciones estratigráficas pronunciadas (?). En particular, el enfoque de refuerzo secuencial de GBR (?) demuestra ser el más eficiente para corregir los residuos de predicción en zonas de alta incertidumbre, minimizando asimetrías y controlando la desviación estándar de los residuos de manera óptima a lo largo de todo el perfil.

Para evaluar la robustez y capacidad de generalización de los algoritmos pro-




FIGURA 6.12

puestos frente a la naturaleza discontinua de los datos geofísicos, se analizó su rendimiento mediante dos enfoques: el comportamiento global bajo diferentes particiones de validación cruzada ($k = 3$ y $k = 5$) y la varianza del error predictivo a lo largo de las columnas del perfil de resistividad eléctrica.

En primer lugar, los gráficos de radar comparativos demuestran la superioridad de los métodos basados en ensambles de árboles de decisión, específicamente *Random Forest* (RF) y *Gradient Boosting Regressor* (GBR). Ambos modelos exhiben una alta estabilidad algorítmica al transicionar de $k = 3$ a $k = 5$ pliegues, manteniendo coeficientes de determinación (R^2) superiores a 0.98 y valores de RMSE y MAE notablemente bajos. Esta baja sensibilidad a la partición de los datos sugiere que RF

y GBR logran capturar la complejidad global del fenómeno geofísico sin incurrir en un sobreajuste (*overfitting*) significativo. En contraste, el modelo de *Support Vector Machine* (SVM) presenta una penalización importante tanto en error absoluto como en varianza, evidenciando una menor flexibilidad para modelar las no-linealidades inherentes de los datos en este espacio de características (?).

Por otro lado, el análisis de la distribución espacial del error (evaluación por índice de columna) expone hallazgos críticos sobre la arquitectura de los modelos. Al observar las métricas iterativas de MSE, Desviación Estándar y Curtosis, se hace evidente que el error predictivo del SVM se degrada sustancialmente (alcanzando valores de MSE superiores a 10,000 en las columnas centrales). Esto se debe a que SVM, al ser un algoritmo de optimización de márgenes espaciales, tiende a perder precisión frente a las transiciones abruptas y capas fuertemente contrastantes típicas de los perfiles de resistividad, a menos que el hiperparámetro de su núcleo (*kernel*) esté calibrado para cada estrato local de forma independiente (?).

Contrariamente, tanto RF como GBR mantienen una traza de error estable y muy cercana a cero a lo largo de todas las columnas geofísicas. La capacidad de los algoritmos basados en árboles para realizar particiones ortogonales y aislar subespacios locales les confiere una ventaja estructural para lidiar con datos espaciales altamente heterogéneos y variaciones estratigráficas pronunciadas (?). En particular, el enfoque de refuerzo secuencial de GBR (?) demuestra ser el más eficiente para corregir los residuos de predicción en zonas de alta incertidumbre, minimizando asimetrías y controlando la desviación estándar de los residuos de manera óptima a lo largo de todo el perfil.

6.4 Test y evaluación

LAMPAZO DEL NARANJO S1-LN-EBSA datos correspondientes a SEV en Lampazos del naranjo, sitio no integrado en el entrenamiento




FIGURA 6.13




FIGURA 6.14




FIGURA 6.15

CAPÍTULO 7 RESULTADOS Y CONCLUSIONES

Adicionalmente durante el entrenamiento se evaluó el rendimiento empleando entradas y salidas de datos (test) con transformación logarítmica, mostrando un pobre desempeño en la evaluación del entrenamiento y predicción.

Tal como se observa en la tabla ??, el modelo Random Forest (RF) selecciona y realiza el entrenamiento empleando como hiperparámetros óptimos los siguientes valores:

TABLA 7.1: Configuración de hiperparámetros para cada modelo. Se remarca en negrita el valor con la mejor generalización mediante k -Fold Cross-Validation usando GridSearchCV.

Algoritmo	Hiperparámetro	Valores Evaluados
Random Forest	n_estimators	200
	max_depth	20
	min_samples_split	2
Support Vector Machine	C	150
	epsilon (ϵ)	0.1
	kernel	Radial Basis Function
Gradient Boosting Regressor	n_estimators	500
	learning_rate	0.1
	max_depth	3

Esta selección es un reflejo de la alta complejidad no lineal en las series, implicando la necesidad de arboles profundos para lograr una buena generalización considerando los cambios sutiles en las curvas de resistividad aparente, al establecer

en 200 el numero de estimadores proporciona la estabilidad necesaria para reducir la varianza inherente a árboles tan profundos.

GBR

El modelo Gradient Boosting Regressor (GBR), optimizado mediante validación cruzada ($k = 5$), demuestra una capacidad predictiva sobresaliente con un R^2 de 0.9884. La configuración de 500 estimadores con baja profundidad permitió capturar la complejidad de los sondeos sin caer en sobreajuste. Aunque el modelo presenta una alta precisión global, la diferencia entre el MAE (13.04) y el RMSE (48.90), sumado a un MAPE del 9.51 %, revela una sensibilidad a valores extremos, comportándose de manera robusta en la mayoría del dominio pero perdiendo precisión en puntos singulares de alta resistividad o ruido elevado.

APÉNDICE A
APÉNDICE I
