

PREDICCIONES DE APERTURAS EN SONDEOS ELECTRICOS VERTICALES

TORRES - SOLANO Juan Jesús - juan.torressln@uanl.edu.mx
 HERNÁNDEZ - SALDAÑA José Anastasio - jose.hernandezsal@uanl.edu.mx
 RIOS - MERCADO Azucena Yoloxóchitl - azucena.riosmr@uanl.edu.mx

1 Introducción

Durante trabajos de exploración geofísica en su modalidad de Sondeos Eléctricos Verticales Schlumberger resulta complicado el muestreo de resistividad de todas las capas que pudieran conformar el una porción del subsuelo (Parasnisi, 2012).

Esto se complica más, si consideramos la heterogeneidad en la distribución de las capas geológicas y su efecto en respuesta de resistividad.

Se busca establecer un modelo de entrenamiento mediante Random Forest que permita realizar predicciones de los intervalos de muestreo, mediante la creación de modelos con datos de espesores, y empleando como variable de entrada a la resistividad para realizar la predicción.

Para lograr este objetivo se emplean datos de 8 sitios, los cuales se integran de 2 a 5 sondeos por sitio, empleando los espesores y resistividad calculada, generamos 100 variantes de cada sondeo, cuidando la proporción de los espesores, se generan resistividades aparentes simulando el arreglo geoeléctrico y 30 posiciones de apertura de electrodos AB/2 los cuales se emplearan para el entrenamiento y posterior predicción.

2 Metodología

A partir de datos de espesor y resistividad calculadas, se realiza una evaluación estadística de los espesores para los sondeos de cada sitio, con el objetivo de establecer los parámetros y criterios para generar variaciones de cada sondeo manteniendo la relación estadística con el conjunto por sitio y por capa.

Empleando la librería PyGIMLI para la simulación de SEV, en las 100 variaciones de cada sondeo, con 30 muestras cada una, Del resultado obtenemos una un dataframe con las columnas Sondeo_ID, Sitio_ID, AB2 y Rha, sumando un conjunto de 75000 registros aproximadamente.

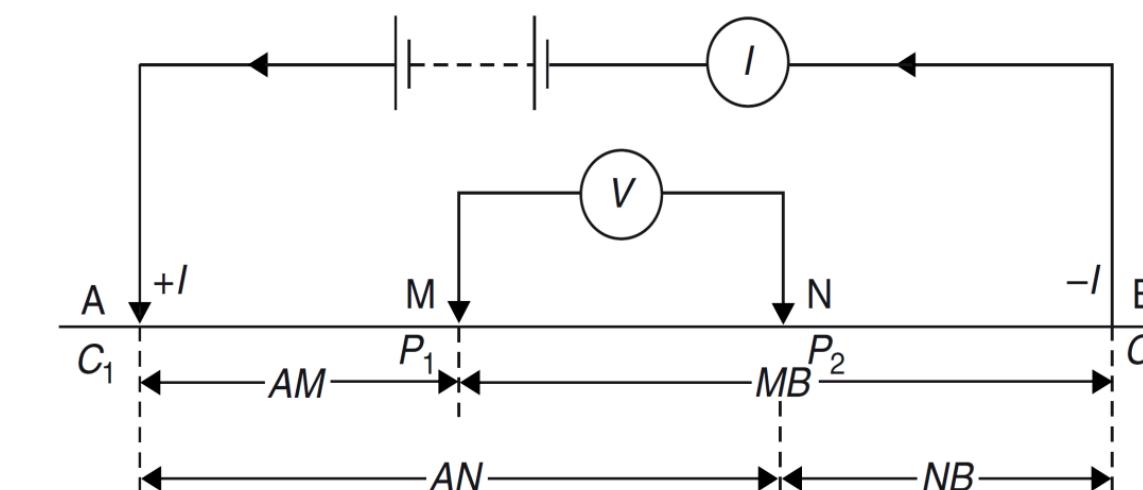
Generando un dataframe denso por sitio para evitar un sub ajuste en el entrenamiento, además de ello se se realizo una analis de los hiperparámetros que se ajustan mejor a cada sitio (`max_depth`, `min_samples_split` y `n_estimators`), en la validación, como valores de prueba se emplean valores reales de Rha, para la predicción de las aperturas de los electrodos mediante Random forest (RF) (Breiman, 2001).

3 Resultados Preliminares

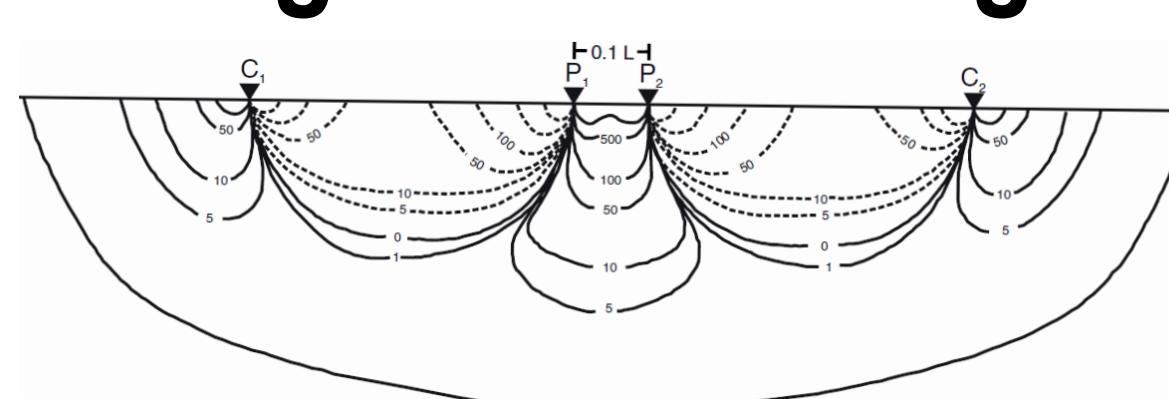
Se implemento la técnica Random forest, considerando como variable de entrada a la resistividad y la variable objetivo AB/2, se identifica el sitio 8, ajustándose a la distribución weibull_min, con un P valor de 0.985 y un KS_stat de 0.12, por lo que se decide emplear como sitio de entrenamiento y predicción, resultando en las gráficos.

Como datos de prueba se emplean los valores reales de resistividad a partir de los cuales realiza la predicción de las aperturas.

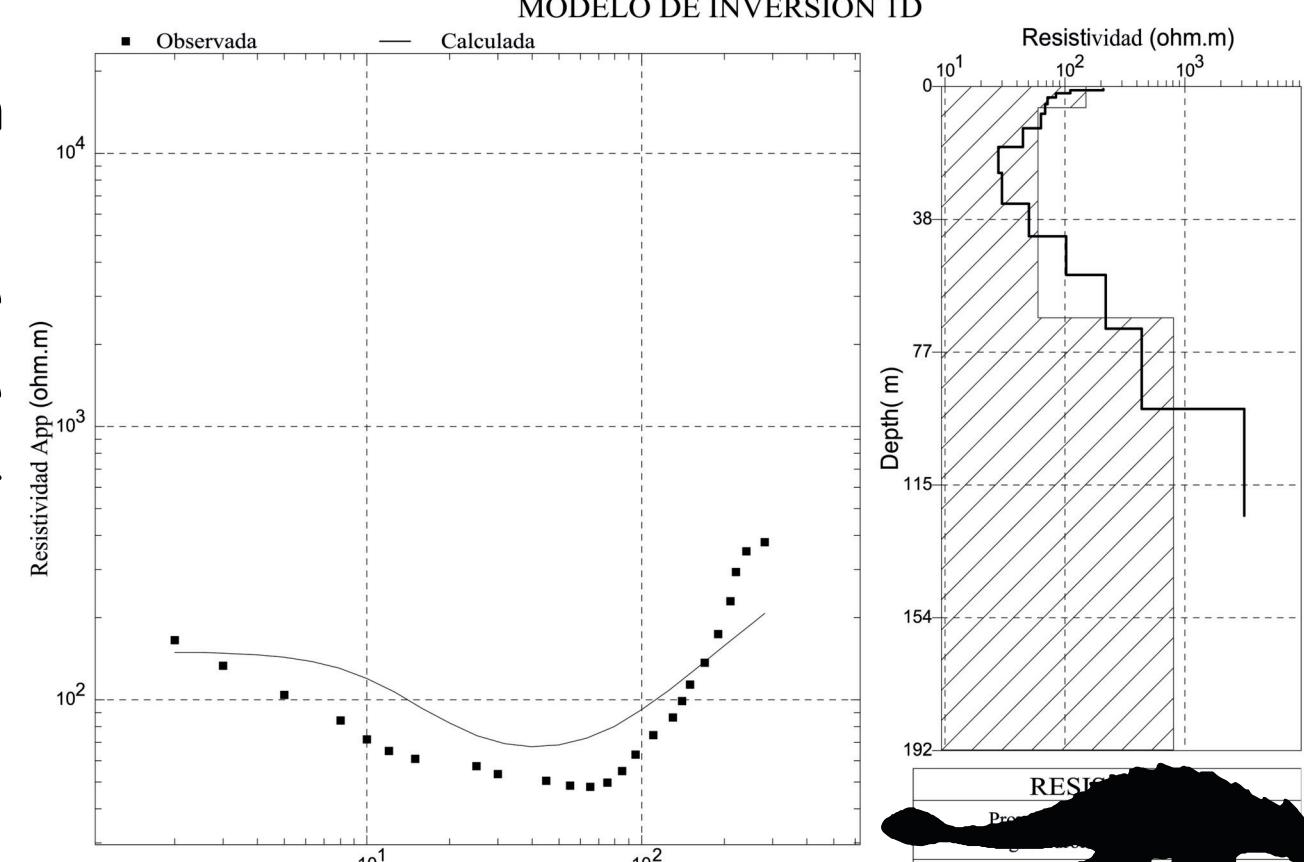
Preparación de arreglo de adquisición



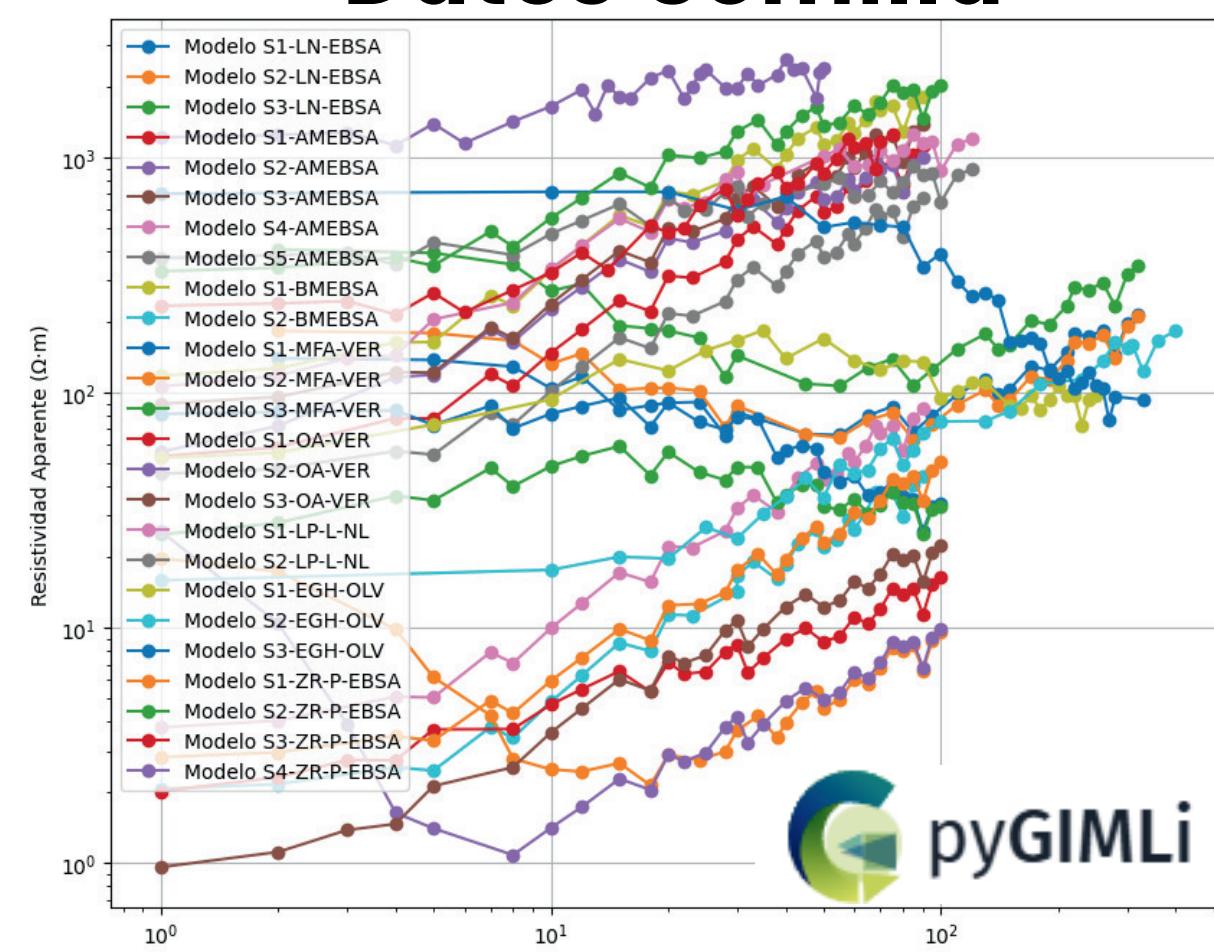
Ejecución del Arreglo Schlumberger



Resistividad medida RESISTERRA



Datos Semilla



Criterios en el Análisis de espesores

Espesores por sitio

-Valor máximo

-Valor mínimo

Mejor Distribución

-P valor

-Kolmogorov-Smirnov

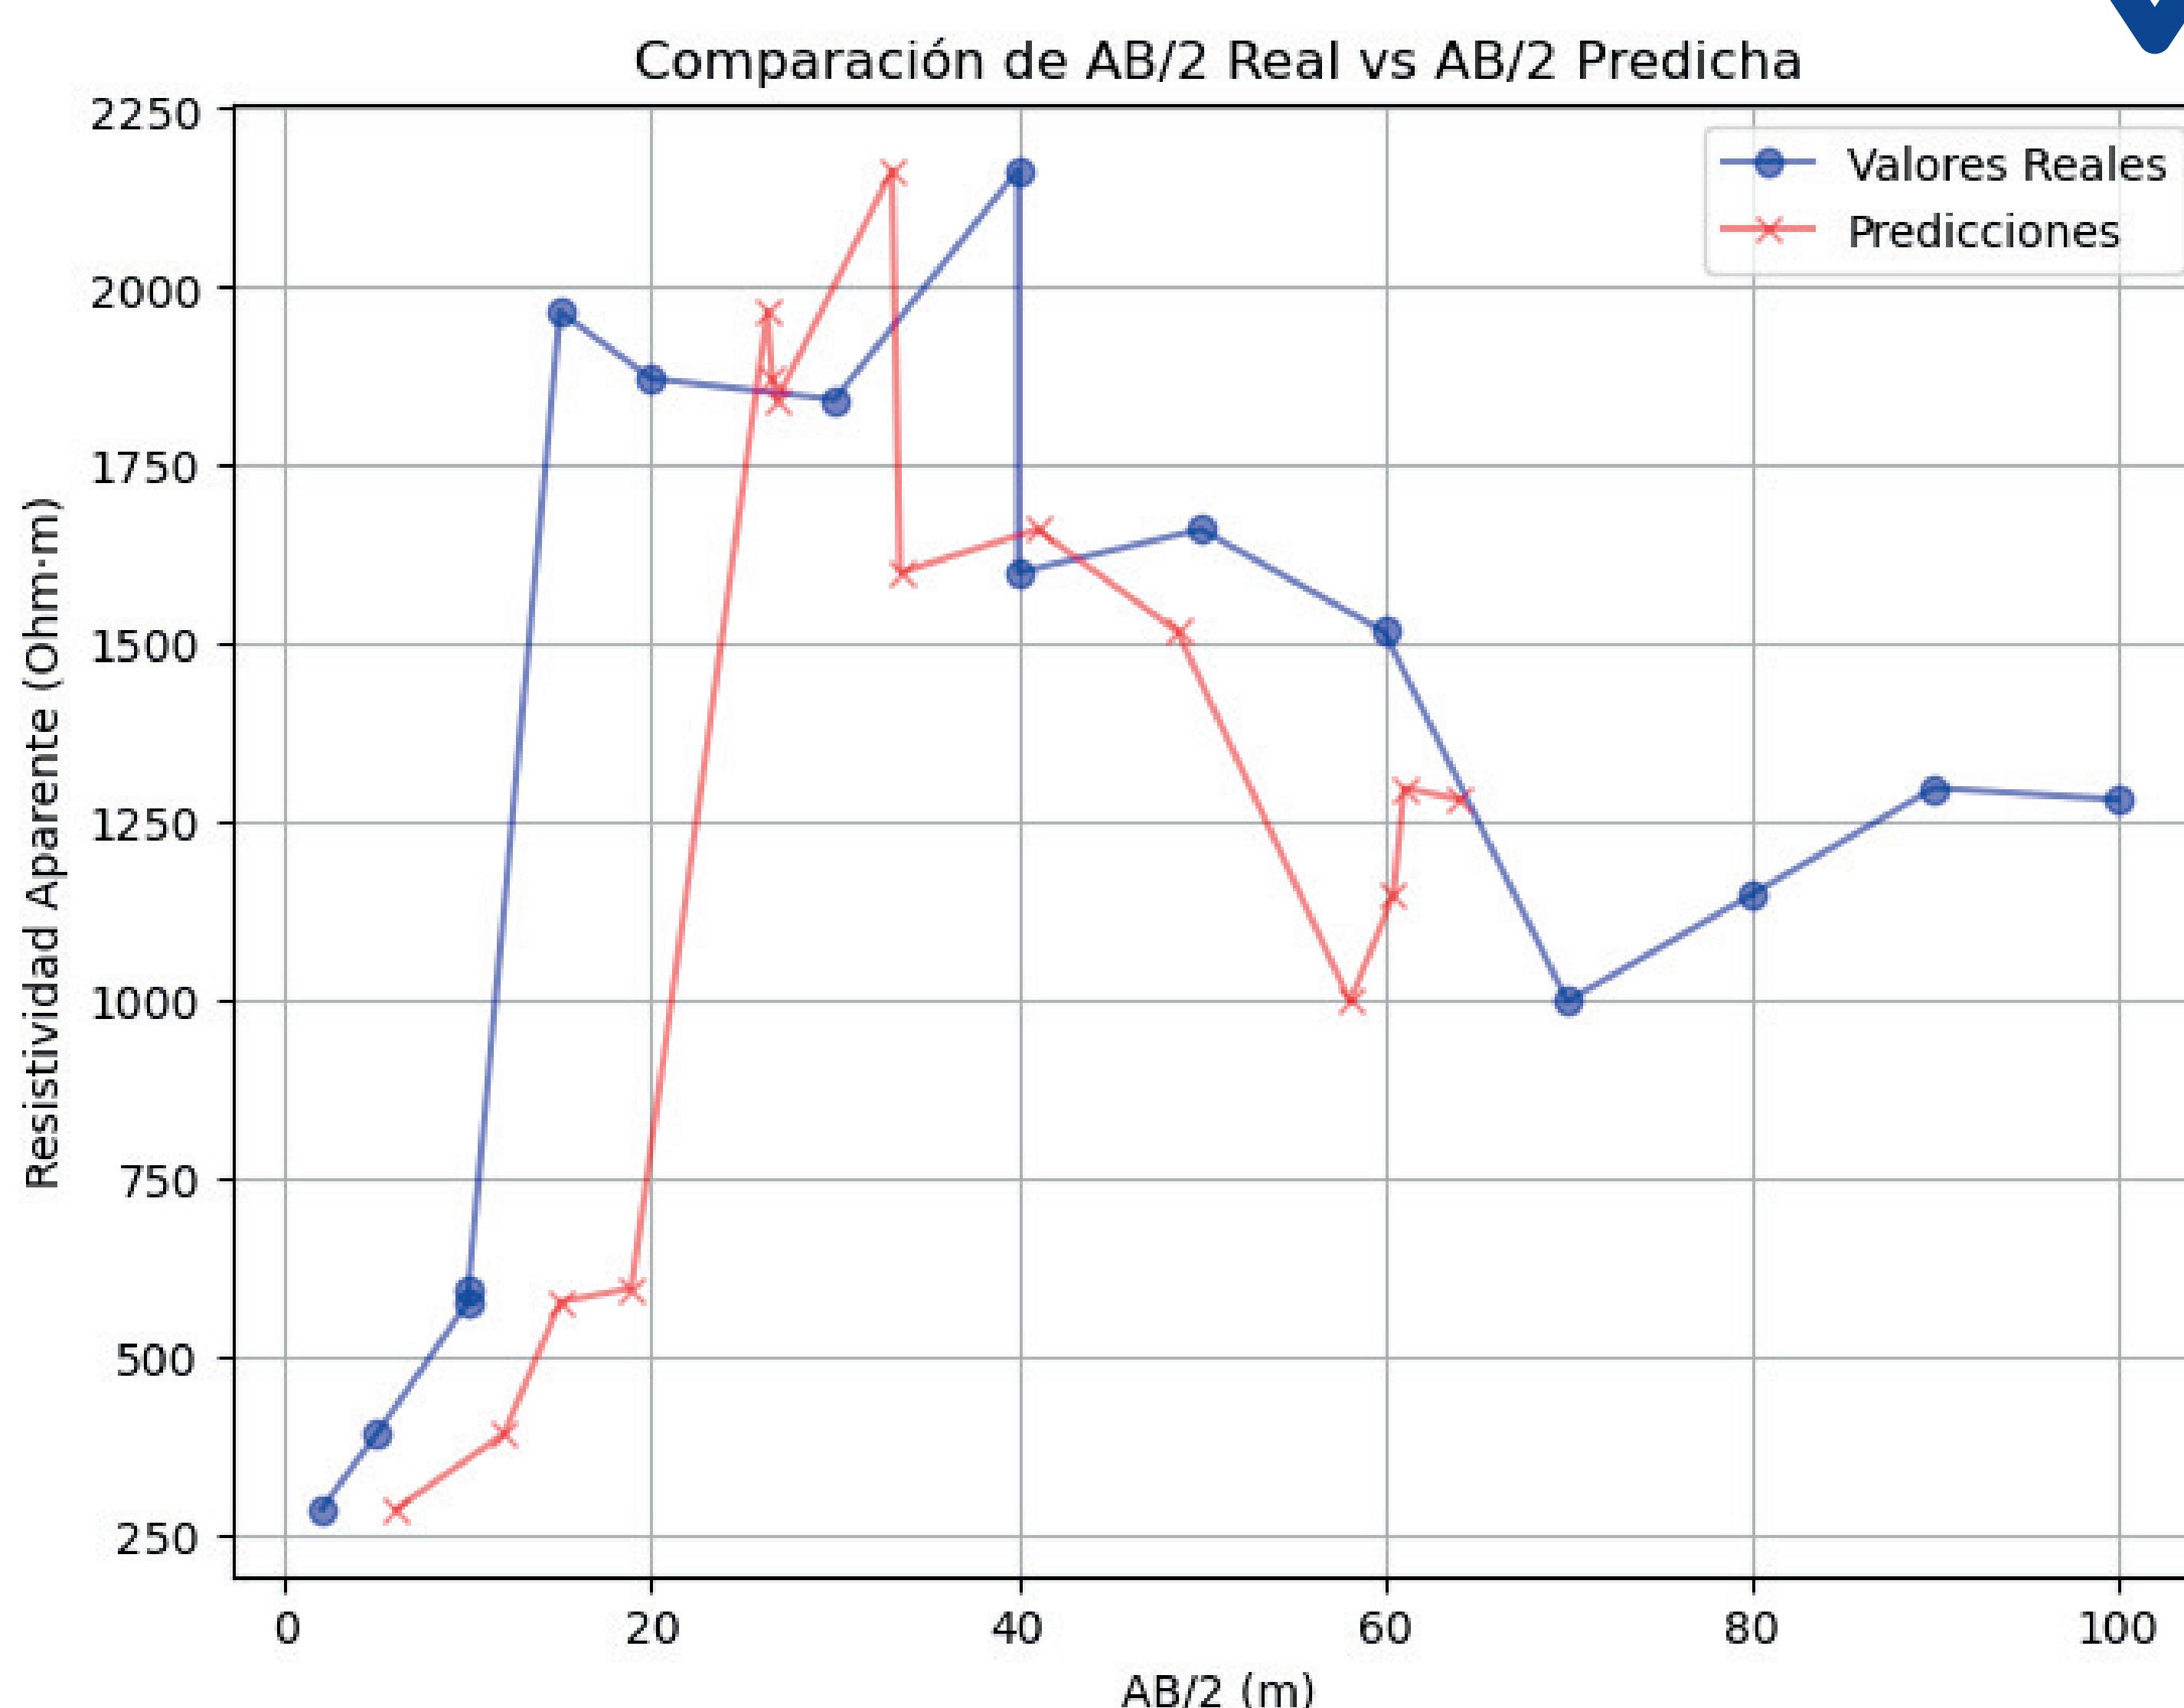
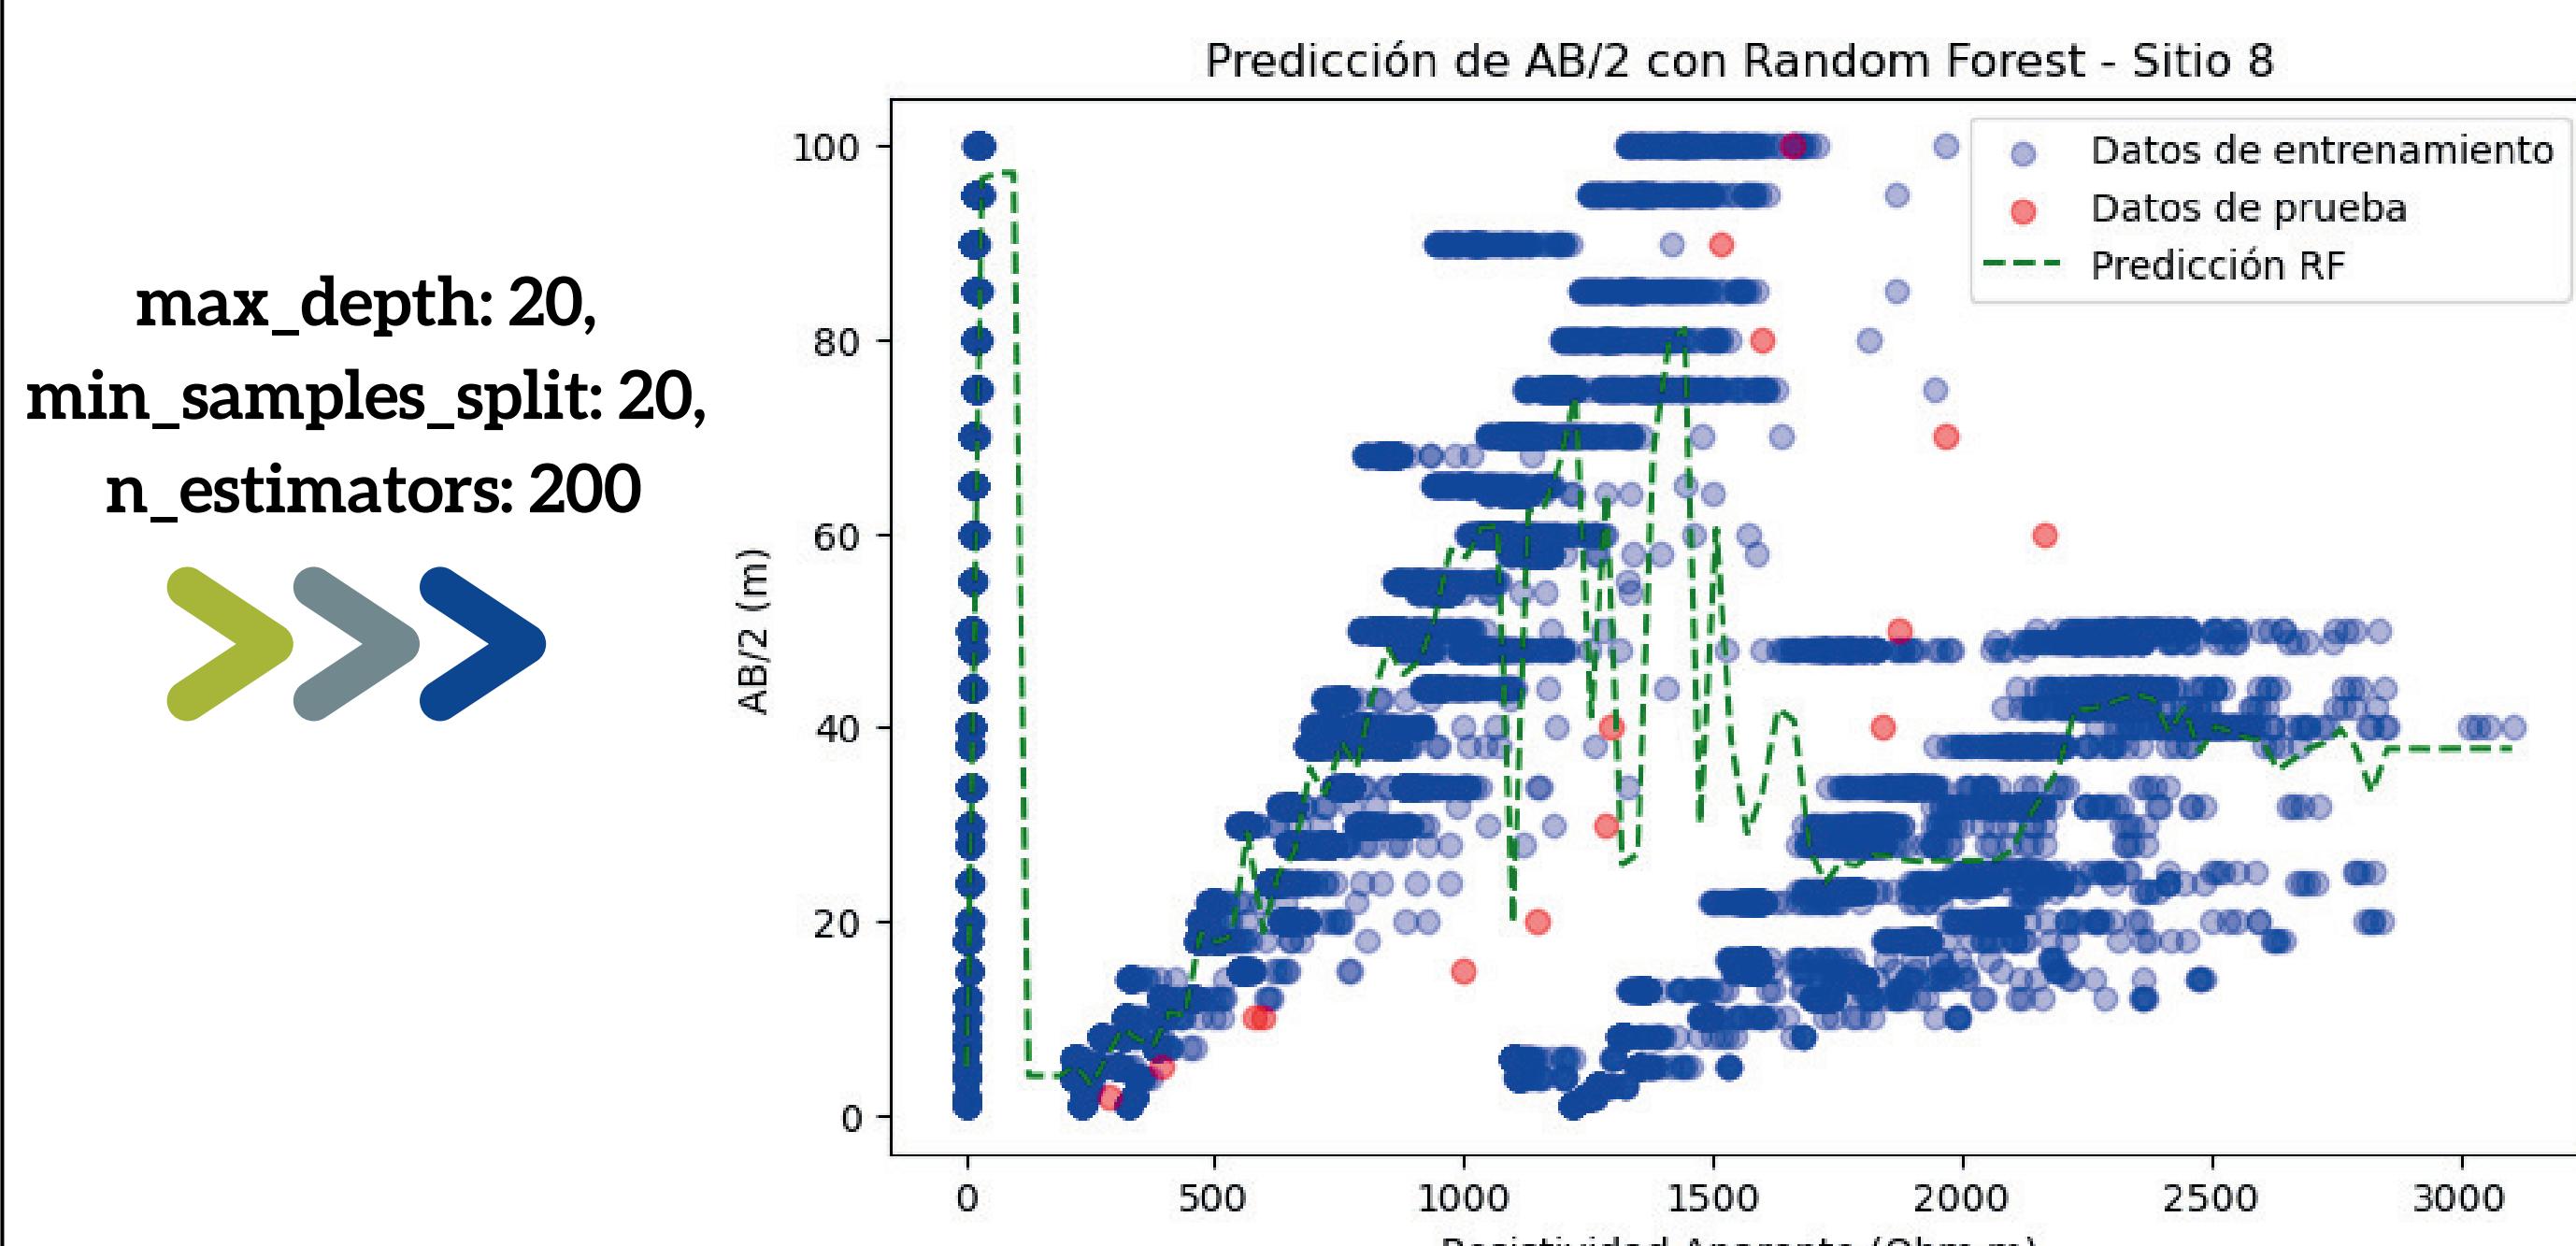
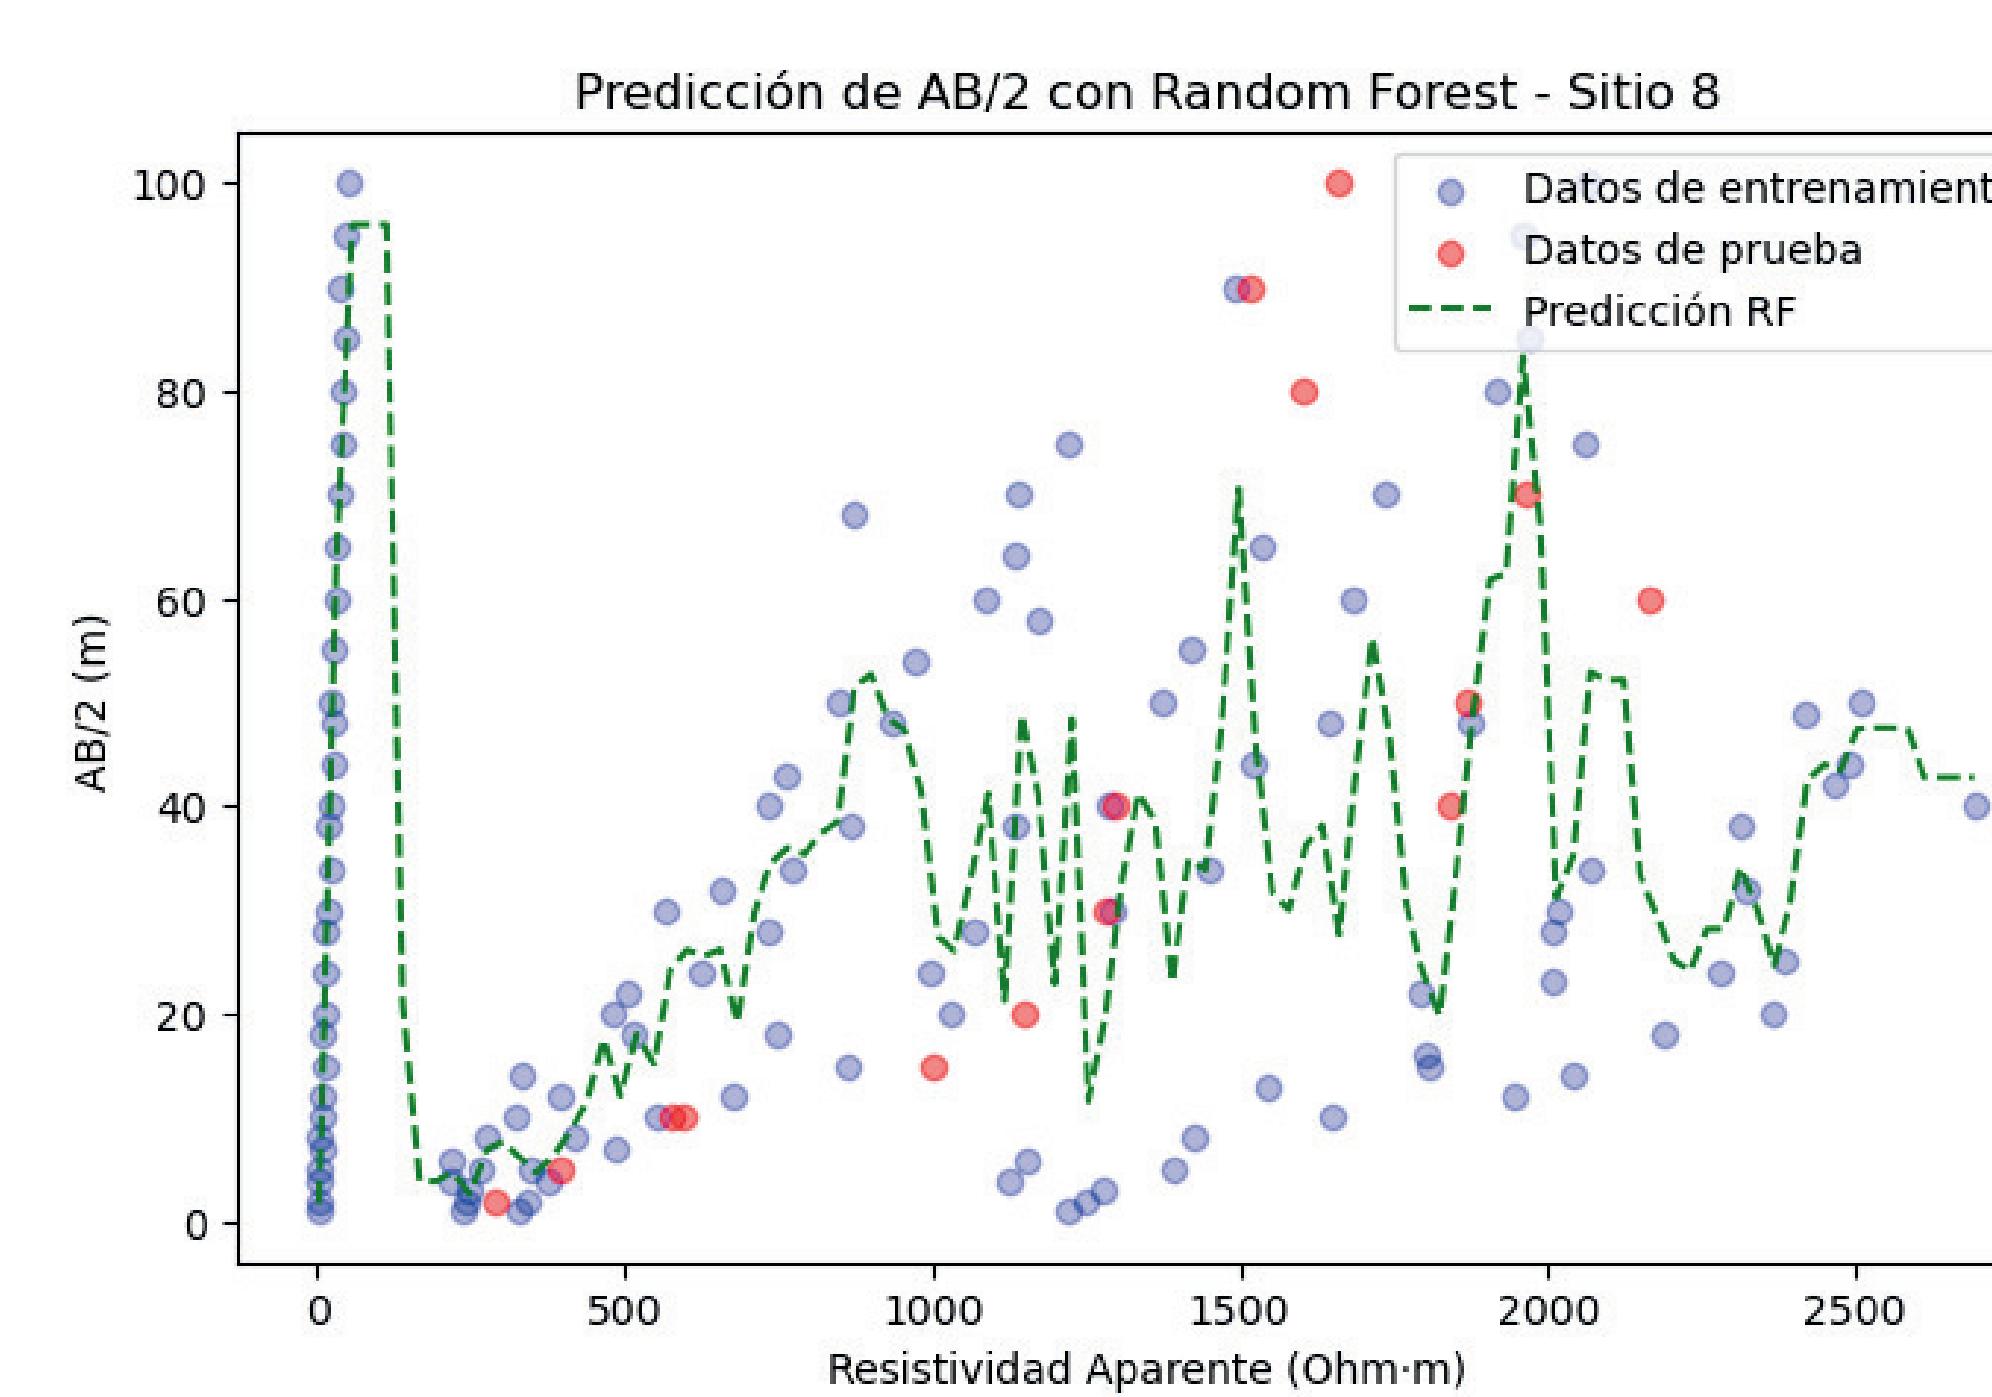
Comprobación mediante de estadísticos básicos

Definición de hiperparámetros



Entrenamiento, prueba y predicción

`max_depth: 5,`
`min_samples_split: 30,`
`n_estimators: 200`



4 Conclusión

A partir del entrenamiento y predicción del sitio 8 podemos observar un buen ajuste de la predicción, sin embargo aun se requieren realizar pruebas adicionales con distintos conjuntos de muestras, así como una mejora en los criterios de creación de variantes a fin de generar un mejor ajuste hacia la distribución y por consiguiente en la generación de espesores para su posterior modelado sintético.

Con lo observado hasta el momento se considera plausible la implementación de esta técnica durante la adquisición en campo, teniendo en cuenta que previo a realizar un trabajo de campo los espesores son estimados así como la resistividad esperada para un sitio definido a partir de su documentación geológica y petrologica.

5 Referencias

- Parasnisi, D. S.(2012), Principles of applied geophysics, Springer Science & Business Media
- Breiman, L.(2001), ((Random forests)), Machine learning, 45, p'ags. 5-32.